

Stats Thèse Briec

Thomas Husson

Table des matières

1	Import de la base et préparation des données	3
2	Introduction	3
3	Conformité au protocole de la méthodologiste	3
4	Méthodes	4
4.A	Patients	4
4.B	Procédures	4
4.C	Critères de jugement	4
4.D	Analyse statistique	4
5	Disclaimer : nombre de sujets nécessaires et précision attendue	6
6	Résultats	8
6.A	Population analysée	8
6.B	Performances test par test	15
6.C	Synthèse globale des tests	20
6.D	Comparaisons directes entre tests	23
6.E	Reproductibilité inter-évaluateurs	24
6.F	Combinaisons et score de positivité ULNT	25
6.G	Analyses par niveau métamérique (regroupé)	28
6.H	Analyse de sensibilité : exclusion des “Douteux”	29

i Origine de ce document

- Ce document est au format Quarto Markdown (.qmd) : il contient du code R et est généré directement pour obtenir un rapport en PDF ou HTML.
- Il est donc à la fois un document de travail pour moi, et à la fois un document de présentation des analyses. Je laisse donc volontairement les sections de code pour transparence et reproductibilité des analyses.
- La préparation des données a été faite sur R plutôt que sur Excel pour éviter les erreurs et tracer les étapes. La première partie du document est donc consacrée à la préparation des données, avec des sections de code pour chaque variable (vous pouvez donc sauter les sections de code si vous ne souhaitez pas les détails de la préparation des données).
- Je suis interne en chirurgie digestive à Paris et actuellement un master 2 en biostatistiques (“Méthodologie et Statistiques en Recherche biomédicale”, Université Paris Saclay). Et accessoirement, ami de Briec !
- Le rapport est disponible en format HTML hébergé sur Github Pages, et aussi téléchargeable en PDF, DOCX et Quarto (.qmd), contenant le code R utilisé pour les analyses.

1 Import de la base et préparation des données

2 Introduction

- 4 tests ULNT (Upper Limb Neurodynamic Tests) : ULNT1, ULNT2a, ULNT2b, ULNT3
- Évaluation de la performance diagnostique de ces tests pour le diagnostic des névralgies cervico-brachiales (NCB) en consultation de chirurgie orthopédique, par rapport à un gold standard principal basé sur l'examen clinique + IRM.

3 Conformité au protocole de la méthodologiste

Les points du protocole couverts sont :

- la description de la population ;
- les performances diagnostiques des tests individuels avec IC95 ;
- les comparaisons directes entre ULNT sur données appariées ;
- la reproductibilité inter-évaluateurs ;
- l'exploration des combinaisons de tests ;
- la lecture exploratoire selon le niveau métamérique, y compris **test par test**.

2 divergences :

- restriction aux 4 ULNT (pas de Scratch Collapse Test)
- pour les gold standard, le second gold standard prévu initialement impliquait la réponse à l'infiltration. Ici, 26 patients ont eu une infiltration, et 24 patients ont des résultats renseignés. On utilise donc la colonne **Gold Standard**

4 Méthodes

4.A Patients

Les données ont été recueillies de manière prospective au CHU de Rennes. Les patients adultes adressés pour une première consultation de chirurgie orthopédique du rachis pour suspicion de névralgie cervico-brachiale ont été inclus dans une base de données dédiée. L'analyse présentée dans ce rapport a porté sur les patients pour lesquels le gold standard principal était renseigné et interprétable dans la base analysée. Dans cette version du recueil, la variable **Gold Standard** ne comportait que deux modalités, **Positif** et **Négatif**, correspondant respectivement à la présence ou à l'absence de névralgie cervico-brachiale selon le gold standard principal.

xxxx

4.B Procédures

4 tests xxxx

4.C Critères de jugement

Critère de jugement principal

Le critère de jugement principal était la performance diagnostique des quatre ULNT pour le diagnostic de névralgie cervico-brachiale, par rapport au gold standard principal. Ce critère reposait sur l'estimation, pour chaque test, de la sensibilité, de la spécificité, des valeurs prédictives positive et négative, ainsi que des rapports de vraisemblance positif et négatif.

4.C.1 Critères de jugement secondaires

Les critères de jugement secondaires comprenaient la comparaison appariée des performances diagnostiques entre ULNT, la reproductibilité inter-évaluateurs entre l'évaluateur 1 et l'évaluateur 2, les performances diagnostiques des combinaisons conjonctives de tests, l'analyse du score global de positivité ULNT et de ses seuils, ainsi qu'une exploration des performances selon le niveau métamérique.

4.D Analyse statistique

Les variables qualitatives ont été décrites par leurs effectifs et pourcentages. Les variables quantitatives ont été décrites par des paramètres de position et de dispersion adaptés à leur distribution. Les données manquantes n'ont pas été imputées.

Les performances diagnostiques des quatre ULNT réalisés par l'évaluateur 1 ont été évaluées par rapport au gold standard principal. Pour chaque test, des tableaux de contingence 2 x 2 ont permis d'estimer la sensibilité, la spécificité, les valeurs prédictives positive et négative, les rapports de vraisemblance positif et négatif, l'indice de Youden et l'aire sous la courbe ROC. Les intervalles de confiance à 95 % des proportions ont été calculés par la méthode binomiale exacte de Clopper-Pearson. L'association entre chaque ULNT et le gold standard principal a été étudiée par le test exact de Fisher.

Les performances des différents ULNT ont été comparées entre elles à l'aide du test de McNemar (χ^2 pour données appariées). La reproductibilité inter-évaluateurs a été évaluée par le coefficient

kappa de Cohen.

Des analyses complémentaires ont porté sur les combinaisons de tests et sur le score global de positivité ULNT, défini comme le nombre total d'ULNT positifs chez un même patient. Les combinaisons conjonctives possibles des quatre ULNT ont été explorées. Le score global a été étudié selon différents seuils de positivité.

Des analyses exploratoires ont également été réalisées selon le niveau métamérique. Pour chaque niveau, la performance de chaque ULNT a été évaluée ainsi que l'association entre le niveau métamérique et la probabilité de névralgie cervico-brachiale.

Les résultats sont présentés sous forme d'estimations ponctuelles avec leurs intervalles de confiance à 95 %. Les modèles logistiques sont présentés sous forme d'odds ratios lorsque cela était pertinent. Les analyses ont été réalisées avec R, version 4.5.2. Tous les tests étaient bilatéraux, avec un seuil de significativité fixé à 0,05. Aucune correction de multiplicité n'a été appliquée aux analyses secondaires ou exploratoires, qui doivent donc être interprétées comme génératrices d'hypothèses.

5 Disclaimer : nombre de sujets nécessaires et précision attendue

Le protocole du CHU de Rennes prévoyait initialement un raisonnement de dimensionnement basé sur la **spécificité**, à partir d’intervalles de confiance exact de Clopper-Pearson. Cette logique faisait varier la spécificité cible, la marge acceptable entre cette cible et la borne inférieure de l’IC95 %, ainsi que la prévalence attendue de la NCB.

11 scénarios théoriques étaient proposés, et sont recalculés ici :

TABLE 1 – Effectif requis pour différents scénarios de spécificité cible, prévalence et marge

Scenario	Target Sp	Prevalence	CI width	Required negatives	Required total N	Lower bound	Computed width
S1	0.90	0.75	0.099	50	200	0.801	0.099
S2	0.90	0.50	0.099	50	100	0.801	0.099
S3	0.90	0.75	0.149	27	108	0.751	0.149
S4	0.90	0.50	0.149	27	54	0.751	0.149
S5	0.90	0.60	0.099	50	125	0.801	0.099
S6	0.90	0.60	0.149	27	68	0.751	0.149
S7	0.85	0.75	0.099	58	232	0.751	0.099
S8	0.85	0.50	0.099	58	116	0.751	0.099
S9	0.85	0.75	0.149	30	120	0.701	0.149
S10	0.85	0.60	0.099	58	145	0.751	0.099
S11	0.85	0.50	0.149	30	60	0.701	0.149

En prenant en compte ce tableau, le choix d’arrêter les inclusions peut poser question : le nombre de sujets négatifs minimal nécessaire pour atteindre la précision visée par “le pire scénario” prévue par la méthodologiste n’est pas acquis. Il faudrait 27 cas négatifs sur un effectif total de 68 patients pour cibler une spécificité de 0,90 avec une marge de 0,149 et une prévalence de 60 %.

Or, dans la cohorte analysée, nous avons 24 cas négatifs sur un effectif total de 69 patients, soit une prévalence de NCB de 65.2 %.

Le nombre total de patients est suffisant, mais le nombre de patients négatifs est légèrement inférieur à ce qui était prévu pour atteindre la précision visée sur la spécificité.

Quel impact ?

- Dans le scénario le plus proche du protocole :
 - Spécificité cible : 0,90
 - Marge de précision prévue (différence entre la spécificité cible et la borne inférieure de l’IC95%) : 0,149
 - Prévalence attendue : 60 %
 - Effectif total requis : 68 patients
 - Effectif négatif requis : 27 patients
- Dans la cohorte analysée :
 - Effectif total : 69 patients
 - Effectif négatif : 24 patients
 - Prévalence observée : 65.2 %
 - Spécificité observée pour la combinaison de tests la plus spécifique : 0.792, avec un IC95% de [0.578 ; 0.929]
 - Marge de précision observée pour la spécificité : 0.213, donc supérieure à la marge

de précision prévue de 0,149

Ce que je propose : faire comme si la méthodologiste n'avait jamais calculé de nombre de sujets requis (parce que sinon, pourquoi avoir arrêté les inclusions avant d'avoir le nombre requis de patients négatifs ?)

6 Résultats

6.A Population analysée

- Variables disponibles : Âge (`df$Age`), Sexe (`df$Sexe`), Côté (`df$Cote`), Niveau (`df$Niveau`), BMI (`df$BMI`), Tabac (`df$Tabac`), Infiltrations (`df$Infiltrations`), Résultat des infiltrations (`df$Resultat_Inf`)

6.A.1 Âge

TABLE 2 – variable âge

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
27	45	51	52	59	77

- Représentation de la variable âge par histogramme avec densité et QQ-plot (le QQ plot se construit en comparant les quantiles de la variable âge à ceux d'une distribution normale théorique : si les points suivent une ligne droite, la variable suit une distribution normale).




FIGURE 1 – Distribution de l'âge

- L'âge semble suivre une distribution approximativement normale. Les tests statistiques de normalité (type Shapiro-Wilk) ont ici un intérêt limité : avec 69 patients, ils peuvent manquer de puissance pour détecter des écarts modestes, tandis que l'inspection graphique reste plus informative.

6.A.2 Sexe




FIGURE 2 – Répartition du sexe

- Même si le camembert est plus visuel, le diagramme en barres est plus précis pour comparer les effectifs et les proportions (car affiche les effectifs totaux).

6.A.2.1 Côté




FIGURE 3 – Répartition du côté

6.A.2.2 Niveau




FIGURE 4 – Répartition du niveau

6.A.2.3 BMI

TABLE 3 – Variable BMI

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.	NA's
17	22.75	25	26.4375	30	45	5

— Le BMI est renseigné chez 64 patients sur 69.




FIGURE 5 – Distribution du BMI

6.A.2.4 Tabac

TABLE 4 – Répartition du tabac

Modalite	Effectif	Pourcentage
Non	37	57.8
Oui	27	42.2

— Le statut tabagique est renseigné chez 64 patients sur 69.




FIGURE 6 – Répartition du tabac

6.A.2.5 Infiltrations

TABLE 5 – Répartition du statut d'infiltration

Modalite	Effectif	Pourcentage
Non	42	61.8
Oui	26	38.2

— Le statut d'infiltration est interprétable chez 68 patients sur 69.




FIGURE 7 – Répartition du statut d'infiltration

6.A.2.6 Résultat des infiltrations

TABLE 6 – Répartition du résultat des infiltrations

Modalite	Effectif	Pourcentage
Negatif	5	20.8
Positif	19	79.2

— Parmi les 26 patients ayant eu une infiltration, le résultat est renseigné chez 24.




FIGURE 8 – Répartition du résultat des infiltrations

6.A.2.7 Tableau de caractéristiques initiales

Caractéristiques	N = 69 ^t
Âge (années)	51 (45, 59)
BMI (kg/m ²)	25.0 (22.5, 30.0)
Sexe	
Masculin	23 (33%)
Féminin	46 (67%)
Côté	
Gauche	35 (51%)
Droite	34 (49%)
Niveau	
C4	1 (1.4%)
C5	10 (14%)
C6	27 (39%)
C7	21 (30%)
C8	10 (14%)
Tabac actif	27 (42%)
Infiltrations	26 (38%)
Résultat des infiltrations	19 (79%)
Gold Standard positif	45 (65%)
ULNT1 E1 positif	48 (70%)
ULNT2a E1 positif	46 (67%)
ULNT2b E1 positif	39 (57%)
ULNT3 E1 positif	25 (36%)

^tMedian (Q1, Q3) ; n (%)

6.B Performances test par test

- La première partie de l'analyse est centrée sur les tests cliniques de l'évaluateur 1
- Elle évalue les performances “tests par tests”
- Une seconde partie agrège résultats et graphiques pour une comparaison globale des tests

6.B.1 ULNT1

6.B.1.1 Résultats

TABLE 7 – Tableau descriptif des résultats de U1 (évaluateur 1)

Test	Positif n (%)	Négatif n (%)
U1	48 (69.6%)	21 (30.4%)

TABLE 8 – Tableau de contingence de U1 par rapport au gold standard

U1	G+	G-	Total
T+	39 (56.5%)	9 (13%)	48 (69.6%)
T-	6 (8.7%)	15 (21.7%)	21 (30.4%)
Total	45 (65.2%)	24 (34.8%)	69 (100%)

- T+/T- correspond à Test positif ou négatif, G+/G- correspond au Gold standard

TABLE 9 – Effectifs diagnostiques de U1 par rapport au gold standard

Test	N	VP	FN	FP	VN
U1	69	39	6	9	15

TABLE 10 – Performances diagnostiques de U1 par rapport au gold standard

Test	Se [IC95]	Sp [IC95]	VPP [IC95]	VPN [IC95]	LR+	LR-	Youden	AUC [IC95]
U1	0.867 [0.732 ; 0.949]	0.625 [0.406 ; 0.812]	0.812 [0.674 ; 0.911]	0.714 [0.478 ; 0.887]	2.31	0.21	0.492	0.746 [0.635 ; 0.857]

6.B.1.2 Interprétation

- Lecture des résultats :
 - Sensibilité : parmi les patients avec NCB, combien ont un test positif
 - Spécificité : parmi les patients sans NCB, combien ont un test
 - VPP : parmi les patients avec un test positif, combien ont une NCB
 - VPN : parmi les patients avec un test négatif, combien n'ont pas de
 - LR+ : combien un test positif augmente la probabilité de NCB
 - LR- : combien un test négatif diminue la probabilité de NCB

- Youden : mesure globale de performance ($Se + Sp - 1$)
- AUC : mesure globale de performance (AUC de la courbe ROC). Pas vraiment un bon indicateur pour un test binaire.
- Interprétation :
 - Sensibilité excellente (0.864) : repère bien les patients avec NCB
 - LR- très bon (0.23) : un test négatif rend la NCB moins probable (utile surtout pour statistiques bayésiennes : probabilité post-test = probabilité pré-test x LR-). Donc si la probabilité pré-test est modérée, un test négatif divise la probabilité par 4 environ.

6.B.2 ULNT2a

6.B.2.1 Résultats

TABLE 11 – Tableau descriptif des résultats de U2a (évaluateur 1)

Test	Positifs n	Positifs %	Négatifs n	Négatifs %
U2a	46	66.7	23	33.3

TABLE 12 – Tableau de contingence de U2a par rapport au gold standard

U2a	G+	G-	Total
T+	36 (52.2%)	10 (14.5%)	46 (66.7%)
T-	9 (13%)	14 (20.3%)	23 (33.3%)
Total	45 (65.2%)	24 (34.8%)	69 (100%)

TABLE 13 – Effectifs diagnostiques de U2a par rapport au gold standard

Test	N	VP	FN	FP	VN
U2a	69	36	9	10	14

TABLE 14 – Performances diagnostiques de U2a par rapport au gold standard

Test	Se [IC95]	Sp [IC95]	VPP [IC95]	VPN [IC95]	LR+	LR-	Youden	AUC [IC95]
U2a	0.8 [0.654 ; 0.904]	0.583 [0.366 ; 0.779]	0.783 [0.636 ; 0.891]	0.609 [0.385 ; 0.803]	1.92	0.34	0.383	0.692 [0.575 ; 0.808]

6.B.2.2 Interprétation

- Moins sensible que U1, mais aussi moins spécifique.
- En témoigne son indice de Youden plus faible que celui de U1, et son LR- moins bon que celui de U1.

6.B.3 ULNT2b

6.B.3.1 Résultats

TABLE 15 – Tableau descriptif des résultats de U2b (évaluateur 1)

Test	Positifs n	Positifs %	Négatifs n	Négatifs %
U2b	39	56.5	30	43.5

TABLE 16 – Tableau de contingence de U2b par rapport au gold standard

U2b	G+	G-	Total
T+	31 (44.9%)	8 (11.6%)	39 (56.5%)
T-	14 (20.3%)	16 (23.2%)	30 (43.5%)
Total	45 (65.2%)	24 (34.8%)	69 (100%)

TABLE 17 – Effectifs diagnostiques de U2b par rapport au gold standard

Test	N	VP	FN	FP	VN
U2b	69	31	14	8	16

TABLE 18 – Performances diagnostiques de U2b par rapport au gold standard

Test	Se [IC95]	Sp [IC95]	VPP [IC95]	VPN [IC95]	LR+	LR-	Youden	AUC [IC95]
U2b	0.689 [0.534 ; 0.818]	0.667 [0.447 ; 0.844]	0.795 [0.635 ; 0.907]	0.533 [0.343 ; 0.717]	2.07	0.47	0.356	0.678 [0.56 ; 0.796]

6.B.3.2 Interprétation

- Profil plus équilibrée entre sensibilité et spécificité que celui de U2a, mais il reste moins bon que U1 pour ne pas manquer les cas. Il est à la fois aussi moins sensible que U1 mais un peu plus spécifique que U1

6.B.4 ULNT3

6.B.4.1 Résultats

TABLE 19 – Tableau descriptif des résultats de U3 (évaluateur 1)

Test	Positifs n	Positifs %	Négatifs n	Négatifs %
U3	25	36.2	44	63.8

TABLE 20 – Tableau de contingence de U3 par rapport au gold standard

U3	G+	G-	Total
T+	18 (26.1%)	7 (10.1%)	25 (36.2%)
T-	27 (39.1%)	17 (24.6%)	44 (63.8%)
Total	45 (65.2%)	24 (34.8%)	69 (100%)

TABLE 21 – Effectifs diagnostiques de U3 par rapport au gold standard

Test	N	VP	FN	FP	VN
U3	69	18	27	7	17

TABLE 22 – Performances diagnostiques de U3 par rapport au gold standard

Test	Se [IC95]	Sp [IC95]	VPP [IC95]	VPN [IC95]	LR+	LR-	Youden	AUC [IC95]
U3	0.4 [0.257 ; 0.557]	0.708 [0.489 ; 0.874]	0.72 [0.506 ; 0.879]	0.386 [0.244 ; 0.545]	1.37	0.85	0.108	0.554 [0.436 ; 0.672]

6.B.4.2 Interprétation

- Le moins sensible de tous (Se **0.386**) mais le plus spécifique (‘Sp 0.71).
- Faible intérêt isolé étant donné son manque de sensibilité

6.C Synthèse globale des tests

TABLE 23 – Tableau global de contingence des ULNT par rapport au gold standard

Test	VP	FN	FP	VN	N
U1	39	6	9	15	69
U2a	36	9	10	14	69
U2b	31	14	8	16	69
U3	18	27	7	17	69

TABLE 24 – Tableau global des performances diagnostiques des ULNT

Test	Se [IC95]	Sp [IC95]	LR+	LR-	AUC [IC95]
U1	0.867 [0.732 ; 0.949]	0.625 [0.406 ; 0.812]	2.31	0.21	0.746 [0.635 ; 0.857]
U2a	0.8 [0.654 ; 0.904]	0.583 [0.366 ; 0.779]	1.92	0.34	0.692 [0.575 ; 0.808]
U2b	0.689 [0.534 ; 0.818]	0.667 [0.447 ; 0.844]	2.07	0.47	0.678 [0.56 ; 0.796]
U3	0.4 [0.257 ; 0.557]	0.708 [0.489 ; 0.874]	1.37	0.85	0.554 [0.436 ; 0.672]




FIGURE 9 – Composition des tableaux de contingence 2x2 par test




FIGURE 10 – Visualisations synthétiques de la performance




FIGURE 11 – Visualisations synthétiques de la performance

Sur les deux graphiques, on voit très bien que :

- ULNT1 est le plus sensible (faux négatif très faible, en rouge sur le premier graphique)
- ULNT3 est le plus spécifique (faux positif plus faible, en orange). Même si ça ne se joue pas à grand chose par rapport aux autres !
- Dans tous les cas, la spécificité est faible
- Aucun des tests pris isolément n'est à la fois sensible et spécifique
- La section suivante compare les tests entre eux pour voir si les différences sont statistiquement significatives. Je ne suis pas sûr que ce soit indispensable (on voit bien que les tests ont des profils différents et il n'y a pas besoin d'un petit p pour ça), mais c'était prévu dans le protocole ! Ça permet quand même de nuancer les différences observées.

6.D Comparaisons directes entre tests

Le protocole prévoyait une comparaison des performances diagnostiques entre les différents ULNT.

L'objectif est de comparer les différences diagnostiques entre tests.

Il s'agit d'effectuer des tests statistiques pour voir si les différences de sensibilité et de spécificité entre les tests sont statistiquement significatives.

Comme les mêmes patients passent les différents ULNT, une comparaison appariée de type McNemar est plus adaptée qu'un simple khi2 indépendant (McNemar = khi2 pour données appariées).

- chez les Gold Standard positif, on compare les **sensibilités** ;
- chez les Gold Standard négatif, on compare les **spécificités**.

TABLE 25 – Comparaisons appariées entre ULNT pour la sensibilité (chez les G+)

Comparaison	N	Test 1	Test 2	Diff.	Discord. (t1 / t2)	p McNemar
U1 vs U2a	45	0.867	0.800	0.067	7 / 4	0.546
U1 vs U2b	45	0.867	0.689	0.178	12 / 4	0.0801
U1 vs U3	45	0.867	0.400	0.467	22 / 1	<0.001
U2a vs U2b	45	0.800	0.689	0.111	8 / 3	0.228
U2a vs U3	45	0.800	0.400	0.400	18 / 0	<0.001
U2b vs U3	45	0.689	0.400	0.289	18 / 5	0.0123

TABLE 26 – Comparaisons appariées entre ULNT pour la spécificité (chez les G-)

Comparaison	N	Test 1	Test 2	Diff.	Discord. (t1 / t2)	p McNemar
U1 vs U2a	24	0.625	0.583	0.042	1 / 0	1
U1 vs U2b	24	0.625	0.667	-0.042	2 / 3	1
U1 vs U3	24	0.625	0.708	-0.083	0 / 2	0.48
U2a vs U2b	24	0.583	0.667	-0.083	2 / 4	0.683
U2a vs U3	24	0.583	0.708	-0.125	0 / 3	0.248
U2b vs U3	24	0.667	0.708	-0.042	2 / 3	1

Même conclusions que les graphiques précédents.

Concernant la sensibilité :

- ULNT1, ULNT2a et ULNT2b sont significativement plus sensibles que ULNT3
- Aucun test ne se démarque sur la spécificité.

6.E Reproductibilité inter-évaluateurs

Par interprétation d'un coefficient de Kappa de Cohen selon les seuils de Landis & Koch (1977)¹

Le coefficient de Kappa de Cohen correspond à la concordance corrigée entre deux évaluateurs, c'est à dire le pourcentage d'accord entre les évaluateurs corrigé par le taux d'accord attendu par hasard (le taux attendu par hasard correspond à la probabilité que les deux évaluateurs soient d'accord simplement par hasard, en fonction de la distribution des réponses).

TABLE 27 – Inter-observer agreement for each ultrasound test

Test	N	Accord	Kappa	IC95% bas	IC95% haut	Interpretation
U1	60	0.883	0.683	0.467	0.899	substantielle
U2a	60	0.833	0.604	0.383	0.824	substantielle
U2b	60	0.817	0.593	0.377	0.808	moderee
U3	60	0.817	0.625	0.425	0.825	substantielle




FIGURE 12 – Kappa inter-observer agreement for each ultrasound test.

Interprétation : Accord substantiel à modéré pour tous les tests. ULNT1 est le plus reproductible.

- < 0 : pas d'accord
- 0.00–0.20 : accord faible
- 0.21–0.40 : accord passable
- 0.41–0.60 : accord modéré
- 0.61–0.80 : accord substantiel
- 0.81–1.00 : accord presque parfait

6.F Combinaisons et score de positivité ULNT

Le protocole prévoyait une exploration des associations entre tests.

2 approches sont possibles :

- Des combinaisons “conjonctives” : combinaisons exactes de 2 à 4 tests, pour lesquelles le résultat est positif seulement si **tous** les tests de la combinaison sont positifs ;
- Un “score de positivité”, qui correspond simplement au **nombre total** de tests positifs, puis à des seuils du type ≥ 1 , ≥ 2 , ≥ 3 ou $= 4$.

Exemple : ≥ 2 positifs correspond à aux moins 2 tests quelqu’ils soient, alors qu’une combinaison conjonctive U2b + U3 impose précisément quels tests doivent être positifs.

6.F.1 Combinaisons conjonctives prédéfinies

- Combinaison la plus sensible : ULNT1 seul (Se 0.864, Sp 0.60).
- Combinaison la plus spécifique : 4 combinaisons à égalité à Sp 0.792 dont le point commun est de toutes contenir ULNT2b et ULNT3. La combinaison retenue pour la meilleure spécificité est ULNT2b et ULNT3 car elle conserve la meilleure sensibilité parmi les ex aequo (Se 0.289), puis la meilleure parcimonie (2 tests au lieu de 3 ou 4).

TABLE 28 – Combinaisons des ULNT avec définition positive conjonctive

Combinaison	Nombre de tests	N analyse	Se [IC95%]	Sp [IC95%]	VPP [IC95%]	VPN [IC95%]	LR+	LR-	Youden
U1	1	69	0.867 [0.732 ; 0.949]	0.625 [0.406 ; 0.812]	0.812 [0.674 ; 0.911]	0.714 [0.478 ; 0.887]	2.31	0.21	0.492
U2a	1	69	0.8 [0.654 ; 0.904]	0.583 [0.366 ; 0.779]	0.783 [0.636 ; 0.891]	0.609 [0.385 ; 0.803]	1.92	0.34	0.383
U2a + U2b	2	69	0.622 [0.465 ; 0.762]	0.75 [0.533 ; 0.902]	0.824 [0.655 ; 0.932]	0.514 [0.34 ; 0.686]	2.49	0.50	0.372
U2b	1	69	0.689 [0.534 ; 0.818]	0.667 [0.447 ; 0.844]	0.795 [0.635 ; 0.907]	0.533 [0.343 ; 0.717]	2.07	0.47	0.356
U1 + U2b	2	69	0.6 [0.443 ; 0.743]	0.75 [0.533 ; 0.902]	0.818 [0.645 ; 0.93]	0.5 [0.329 ; 0.671]	2.40	0.53	0.350
U1 + U2a	2	69	0.711 [0.557 ; 0.836]	0.625 [0.406 ; 0.812]	0.78 [0.624 ; 0.894]	0.536 [0.339 ; 0.725]	1.90	0.46	0.336
U1 + U2a + U2b	3	69	0.533 [0.379 ; 0.683]	0.75 [0.533 ; 0.902]	0.8 [0.614 ; 0.923]	0.462 [0.301 ; 0.628]	2.13	0.62	0.283
U3	1	69	0.4 [0.257 ; 0.557]	0.708 [0.489 ; 0.874]	0.72 [0.506 ; 0.879]	0.386 [0.244 ; 0.545]	1.37	0.85	0.108
U2a + U3	2	69	0.4 [0.257 ; 0.557]	0.708 [0.489 ; 0.874]	0.72 [0.506 ; 0.879]	0.386 [0.244 ; 0.545]	1.37	0.85	0.108
U1 + U3	2	69	0.378 [0.238 ; 0.535]	0.708 [0.489 ; 0.874]	0.708 [0.489 ; 0.874]	0.378 [0.238 ; 0.535]	1.30	0.88	0.086
U1 + U2a + U3	3	69	0.378 [0.238 ; 0.535]	0.708 [0.489 ; 0.874]	0.708 [0.489 ; 0.874]	0.378 [0.238 ; 0.535]	1.30	0.88	0.086
U2b + U3	2	69	0.289 [0.164 ; 0.443]	0.792 [0.578 ; 0.929]	0.722 [0.465 ; 0.903]	0.373 [0.241 ; 0.519]	1.39	0.90	0.081
U2a + U2b + U3	3	69	0.289 [0.164 ; 0.443]	0.792 [0.578 ; 0.929]	0.722 [0.465 ; 0.903]	0.373 [0.241 ; 0.519]	1.39	0.90	0.081
U1 + U2b + U3	3	69	0.267 [0.146 ; 0.419]	0.792 [0.578 ; 0.929]	0.706 [0.44 ; 0.897]	0.365 [0.236 ; 0.51]	1.28	0.93	0.058
U1 + U2a + U2b + U3	4	69	0.267 [0.146 ; 0.419]	0.792 [0.578 ; 0.929]	0.706 [0.44 ; 0.897]	0.365 [0.236 ; 0.51]	1.28	0.93	0.058

6.F.2 “Score de positivité” : performances selon le nombre de tests positifs

L’objectif ici est de calculer les performances diagnostiques (sensibilité, spécificité, LR+, LR-, Youden, DOR) pour différents seuils de score (≥ 1 , ≥ 2 , ≥ 3 , ≥ 4 tests positifs).

Cela revient à demander si un seuil du type “au moins 2 tests positifs” est plus utile qu’un test isolé. Cette logique reste différente de celle des combinaisons conjonctives : ≥ 3 positifs ne précise pas quels tests sont positifs, alors que U2b + U3 impose une paire fixe de tests positifs.

Le score correspond simplement au **nombre de tests ULNT positifs** chez un même patient ; un test peut donc être très spécifique pris isolément, mais modifie peu le score si les rares patients qu’il rend positifs le sont déjà par d’autres ULNT.

TABLE 29 – Performances diagnostiques selon le seuil du score

Seuil	Se [IC95%]	Sp [IC95%]	LR+	LR-	Youden	DOR [IC95%]
≥ 1 positif	0.956 [0.849 ; 0.995]	0.5 [0.291 ; 0.709]	1.911	0.089	0.456	21.5 [4.221 ; 109.512]
≥ 2 positifs	0.867 [0.732 ; 0.949]	0.625 [0.406 ; 0.812]	2.311	0.213	0.492	10.833 [3.288 ; 35.693]
≥ 3 positifs	0.667 [0.51 ; 0.8]	0.667 [0.447 ; 0.844]	2.000	0.500	0.333	4 [1.398 ; 11.441]
≥ 4 positifs	0.267 [0.146 ; 0.419]	0.792 [0.578 ; 0.929]	1.280	0.926	0.058	1.382 [0.422 ; 4.525]

NB : Le **DOR** (diagnostic odds ratio) résume en un seul chiffre la capacité globale du score à distinguer les patients G+ des G- (se calcule en faisant le rapport entre le LR+ et le LR-), mais il reste ici secondaire car moins intuitif cliniquement que la sensibilité, la spécificité et les rapports de vraisemblance. En plus, les IC du DOR sont ici très larges et se chevauchent largement, donc ils ne sont pas vraiment interprétables.

Pour interpréter ces résultats, on peut raisonner **par addition** (approche de type Shapley) : on calcule la **contribution moyenne** de chaque test au gain de sensibilité du score global.




FIGURE 13 – Contribution de chaque test au gain de sensibilité du score

— Ce graphique montre clairement que l’ULNT1 (en vert foncé) est le principal contributeur à la

sensibilité du score, quel que soit le seuil choisi. Ajouter les autres tests augmente la spécificité mais au prix d'une perte importante de sensibilité.

6.G Analyses par niveau métamérique (regroupé)

Objectif exploratoire car les effectifs par niveau précis sont trop faibles pour une interprétation robuste. Nous regroupons ici les niveaux en deux étages : **Supérieur (C4-C6)** et **Inférieur (C7-C8)**.

TABLE 30 – Performances de l’ULNT1 par étage métamérique

Étage	N	NCB+	NCB-	Sensibilité (U1)	Spécificité (U1)
C4-C6	38	25	13	0.88	0.5384615
C7-C8	31	20	11	0.85	0.7272727




FIGURE 14 – Sensibilité et Spécificité (ULNT1) selon l’étage métamérique

Globalement, le regroupement confirme la bonne sensibilité de l’ULNT1 sur les deux étages, bien que les effectifs restent limités pour conclure à une différence majeure de performance selon le niveau.

6.H Analyse de sensibilité : exclusion des “Douteux”

Dans l’analyse principale, les patients ayant un Gold Standard “Douteux” ont été classés comme négatifs. Nous vérifions ici si leur exclusion pure et simple modifie les résultats.

TABLE 31 – Comparaison avec et sans les patients ‘Douteux’

Metrique	Analyse_Principale	Exclusion_Douteux
Sensibilité (U1)	0.867	0.867
Spécificité (U1)	0.625	0.625

- Les résultats sont **très proches**, ce qui suggère que le choix de codage des patients “Douteux” n’introduit pas de biais majeur dans l’évaluation des tests ULNT.

Références

- [1] J. R. Landis and G. G. Koch. The measurement of observer agreement for categorical data. *Biometrics*, 33(1) :159–174, March 1977.