

Stats Thèse Briec

Thomas Husson

Table des matières

1	Import de la base et préparation des données	3
1.A	Dates	3
1.B	Variables numériques	3
1.C	Variables catégorielles	3
2	Introduction	8
3	Justification de l'effectif	9
4	Résultats des tests pris individuellement	11
4.A	Caractéristiques initiales de la population	11
4.B	Résultat des tests cliniques (test par test)	15
4.C	Résultats globaux résumés	25
4.D	Résultats par niveaux métamériques	28
4.E	Reproductibilité inter-évaluateurs	30
5	Résultats des tests en les combinant	30
5.A	Probabilité de NCB en fonction du nombre de tests positifs	31
5.B	Score de positivité : performances diagnostiques selon les seuils de score	31

i Origine de ce document

- Ce document est au format Quarto Markdown (.qmd) : il contient du code R et est généré directement pour obtenir un rapport en PDF ou HTML.
- Il est donc à la fois un document de travail pour moi, et à la fois un document de présentation des analyses. Je laisse donc volontairement les sections de code pour transparence et reproductibilité des analyses.
- La préparation des données a été faite sur R plutôt que sur Excel pour éviter les erreurs et tracer les étapes. La première partie du document est donc consacrée à la préparation des données, avec des sections de code pour chaque variable (vous pouvez donc sauter les sections de code si vous ne souhaitez pas les détails de la préparation des données).
- Je suis interne en chirurgie digestive à Paris et actuellement un master 2 en biostatistiques (“Méthodologie et Statistiques en Recherche biomédicale”, Université Paris Saclay). Et accessoirement, ami de Briec !
- Le rapport est disponible en format HTML hébergé sur Github Pages, et aussi téléchargeable en PDF, DOCX et Quarto (.qmd), contenant le code R utilisé pour les analyses.

1 Import de la base et préparation des données

1.A Dates

1.B Variables numériques

```
# Convertir les variables numériques
df$Age <- as.numeric(df$Age)
class(df$Age)
```

1.C Variables catégorielles

1.C.1 Sexe

```
# Convertir la variable "Sexe" en facteur
df$Sexe <- factor(c(M = "Masculin", F = "Féminin")[df$Sexe], levels = c("Masculin",
↪ "Féminin"))
table(df$Sexe, useNA = "ifany")
```

1.C.2 Côté

```
# Convertir la variable "Côté" en facteur
df$Cote <- factor(
  c(G = "Gauche", D = "Droite")[df$Cote],
  levels = c("Gauche", "Droite")
)
table(df$Cote, useNA = "ifany")
```

1.C.3 Niveau

```
# Convertir la variable "Niveau" en facteur ordonné
df$Niveau
df$Niveau <- factor(
  df$Niveau,
  levels = c("C4", "C5", "C6", "C7", "C8"),
  ordered = TRUE
)
table(df$Niveau, useNA = "ifany")
```

1.C.4 Examen clinique

```

str(df$Examen_Clinique)
class(df$Examen_Clinique)
unique(df$Examen_Clinique)
#création d'une variable binaire "Examen_Clinique_Binaire" (1 = Positif, 0 = Negatif ou
↪ Douteux)
df$Examen_Clinique_Positif_YN <- ifelse(df$Examen_Clinique == "Positif", 1, 0)
table(df$Examen_Clinique_Positif_YN, useNA = "ifany")
#création d'une variable binaire "Examen_Clinique_Douteux_YN" (1 = Douteux, 0 = Positif ou
↪ Negatif)
df$Examen_Clinique_Douteux_YN <- ifelse(df$Examen_Clinique == "Douteux", 1, 0)
table(df$Examen_Clinique_Douteux_YN, useNA = "ifany")

```

1.C.5 IRM

```

str(df$IRM)
class(df$IRM)
unique(df$IRM)
#création d'une variable binaire "IRM_Positif_YN" (1 = Positif, 0 = Negatif ou Douteux)
df$IRM_Positif_YN <- ifelse(df$IRM == "Positif", 1, 0)
table(df$IRM_Positif_YN, useNA = "ifany")
#création d'une variable binaire "IRM_Douteux_YN" (1 = Douteux, 0 = Positif ou Negatif)
df$IRM_Douteux_YN <- ifelse(df$IRM == "Douteux", 1, 0)
table(df$IRM_Douteux_YN, useNA = "ifany")

```

1.C.6 Infiltrations

```

str(df$Infiltrations)
class(df$Infiltrations)
unique(df$Infiltrations)
#modification infiltrations pour mettre 1 et 0
df$Infiltrations <- ifelse(df$Infiltrations == "oui", 1, ifelse(df$Infiltrations == "non",
↪ 0, NA))
table(df$Infiltrations, useNA = "ifany")

```

1.C.7 Gold Standard

```

#création d'une variable binaire "Gold_Standard_Positif_YN" (1 = Positif, 0 = Negatif ou
↪ Douteux ou NA)
df$Gold_Standard_Positif_YN <- ifelse(df$Gold_Standard == "Positif", 1,
  ifelse(df$Gold_Standard %in% c("Negatif", "Douteux"), 0, NA)
)
table(df$Gold_Standard_Positif_YN, useNA = "ifany")

```

```
#création d'une variable binaire "Gold_Standard_Douteux_YN" (1 = Douteux, 0 = Positif ou
↪ Negatif ou NA)
df$Gold_Standard_Douteux_YN <- ifelse(df$Gold_Standard == "Douteux", 1,
  ifelse(df$Gold_Standard %in% c("Positif", "Negatif"), 0, NA)
)
table(df$Gold_Standard_Douteux_YN, useNA = "ifany")
```

1.C.8 Tests cliniques évaluateur 1

Les variables sont transformées en numériques binaires (1 = Positif / 0 = Negatif) pour faciliter les tests.

1.C.8.1 U1_E1

```
str(df$U1_E1)
class(df$U1_E1)
table(df$U1_E1, useNA = "ifany")
#création d'une variable binaire "U1_E1_Positif_YN" (1 = Positif, 0 = Negatif ou NA)
df$U1_E1_positif <- as.numeric(df$U1_E1 == "Positif")
table(df$U1_E1_positif, useNA = "ifany")
```

1.C.8.2 U2a_E1

```
str(df$U2a_E1)
class(df$U2a_E1)
table(df$U2a_E1, useNA = "ifany")
#création d'une variable binaire "U2a_E1_Positif_YN" (1 = Positif, 0 = Negatif ou NA)
df$U2a_E1_positif <- as.numeric(df$U2a_E1 == "Positif")
table(df$U2a_E1_positif, useNA = "ifany")
```

1.C.8.3 U2b_E1

```
str(df$U2b_E1)
class(df$U2b_E1)
table(df$U2b_E1, useNA = "ifany")
#création d'une variable binaire "U2b_E1_Positif_YN" (1 = Positif, 0 = Negatif ou NA)
df$U2b_E1_positif <- as.numeric(df$U2b_E1 == "Positif")
table(df$U2b_E1_positif, useNA = "ifany")
```

1.C.8.4 U3_E1

```
str(df$U3_E1)
class(df$U3_E1)
table(df$U3_E1, useNA = "ifany")
#création d'une variable binaire "U3_E1_Positif_YN" (1 = Positif, 0 = Negatif ou NA)
df$U3_E1_positif <- as.numeric(df$U3_E1 == "Positif")
table(df$U3_E1_positif, useNA = "ifany")
```

1.C.8.5 Sc_E1

Il existe un “NT” dans Sc_E1, traité comme NA

```
str(df$Sc_E1)
class(df$Sc_E1)
table(df$Sc_E1, useNA = "ifany")
# conversion de "NT" en NA
df$Sc_E1 <- ifelse(df$Sc_E1 == "NT", NA, df$Sc_E1)
table(df$Sc_E1, useNA = "ifany")
#création d'une variable binaire "Sc_E1_Positif_YN" (1 = Positif, 0 = Negatif ou NA)
df$Sc_E1_positif <- as.numeric(df$Sc_E1 == "Positif")
table(df$Sc_E1_positif, useNA = "ifany")
```

1.C.8.6 Gachette évaluateur 1

Renommage de la variable “Gachette” en “Gachette_E1” pour plus de clarté

```
# Renommage de la variable "Gachette" en "Gachette1"
names(df)[names(df) == "Gachette"] <- "Gachette1"
table(df$Gachette1, useNA = "ifany")
# transformation de la variable en factoriel non ordonné
df$Gachette1 <- factor(df$Gachette1, levels = c("paraspinal", "susclavier"))
table(df$Gachette1, useNA = "ifany")
class(df$Gachette1)
```

1.C.8.7 Tests cliniques évaluateur 2

1.C.8.8 U1_E2

```
str(df$U1_E2)
class(df$U1_E2)
table(df$U1_E2, useNA = "ifany")
#transformation NT en NA
df$U1_E2 <- ifelse(df$U1_E2 == "NT", NA, df$U1_E2)
table(df$U1_E2, useNA = "ifany")
```

```
#création d'une variable binaire "U1_E2_Positif_YN" (1 = Positif, 0 = Negatif ou NA)
df$U1_E2_positif <- as.numeric(df$U1_E2 == "Positif")
table(df$U1_E2_positif, useNA = "ifany")
```

1.C.8.9 U2a_E2

```
str(df$U2a_E2)
class(df$U2a_E2)
table(df$U2a_E2, useNA = "ifany")
#transformation NT en NA
df$U2a_E2 <- ifelse(df$U2a_E2 == "NT", NA, df$U2a_E2)
table(df$U2a_E2, useNA = "ifany")
#création d'une variable binaire "U2a_E2_Positif_YN" (1 = Positif, 0 = Negatif ou NA)
df$U2a_E2_positif <- as.numeric(df$U2a_E2 == "Positif")
table(df$U2a_E2_positif, useNA = "ifany")
```

1.C.8.10 U2b_E2

```
str(df$U2b_E2)
class(df$U2b_E2)
table(df$U2b_E2, useNA = "ifany")
#transformation NT en NA
df$U2b_E2 <- ifelse(df$U2b_E2 == "NT", NA, df$U2b_E2)
table(df$U2b_E2, useNA = "ifany")
#création d'une variable binaire "U2b_E2_Positif_YN" (1 = Positif, 0 = Negatif ou NA)
df$U2b_E2_positif <- as.numeric(df$U2b_E2 == "Positif")
table(df$U2b_E2_positif, useNA = "ifany")
```

1.C.8.11 U3_E2

```
str(df$U3_E2)
class(df$U3_E2)
table(df$U3_E2, useNA = "ifany")
#transformation NT en NA
df$U3_E2 <- ifelse(df$U3_E2 == "NT", NA, df$U3_E2)
table(df$U3_E2, useNA = "ifany")
#création d'une variable binaire "U3_E2_Positif_YN" (1 = Positif, 0 = Negatif ou NA)
df$U3_E2_positif <- as.numeric(df$U3_E2 == "Positif")
table(df$U3_E2_positif, useNA = "ifany")
```

1.C.8.12 Sc_E2

```
str(df$Sc_E2)
class(df$Sc_E2)
table(df$Sc_E2, useNA = "ifany")
#transformation NT en NA
df$Sc_E2 <- ifelse(df$Sc_E2 == "NT", NA, df$Sc_E2)
table(df$Sc_E2, useNA = "ifany")
#création d'une variable binaire "Sc_E2_Positif_YN" (1 = Positif, 0 = Négatif ou NA)
df$Sc_E2_positif <- as.numeric(df$Sc_E2 == "Positif")
table(df$Sc_E2_positif, useNA = "ifany")
```

2 Introduction

- 4 tests ULNT (Upper Limb Neurodynamic Tests) : ULNT1, ULNT2a, ULNT2b, ULNT3
- Qu'il faut comparer à deux gold standards :
 - Gold standard 1 : diagnostic d'une névralgie cervico-brachiale par examen clinique + IRM et consensus entre 2 orthopédistes seniors
 - Gold standard 2 : diagnostic d'une névralgie cervico-brachiale par examen clinique + IRM par un orthopédiste senior + résultat positif à une infiltration et/ou geste chirurgical
- Objectif : Évaluation de la performance diagnostique, par rapport au gold standard, des ULNT et du Scratch Collapse Test pour le le diagnostic des névralgies cervicobrachiales en consultation de chir ortho.

3 Justification de l'effectif

- Dans le protocole, un calcul de taille d'échantillon centré sur la **précision de la spécificité** par intervalle de confiance exact de Clopper-Pearson est fourni (= intervalle de confiance calculé en utilisant la distribution binomiale, plutôt que la distribution normale classique; permet d'obtenir des intervalles de confiance plus précis, notamment pour les proportions proches de 0 ou de 1, ou pour les petits échantillons).
- D'abord, il ne s'agit pas d'un calcul de puissance classique comme pour un test d'hypothèse : ici, l'objectif est que les tests soient performants pour éliminer une NCB chez les patients qui n'en ont pas.
- Il s'agit de
 - fixer une spécificité cible t à atteindre, par exemple **0,85** ou **0,90** (c'est à dire que le test doit être négatif chez au moins 85% ou 90% des patients qui n'ont pas de NCB)
 - fixer une marge inférieure acceptable ω , définie comme l'écart maximal tolérée entre cette spécificité cible et la limite inférieure de l'intervalle de confiance à 95% : par exemple, si $t = 0,85$ et $\omega = 0,15$, alors la limite inférieure de l'intervalle de confiance doit être au moins égale à **0,70** (c'est à dire que même dans le pire des cas, la spécificité du test ne serait pas inférieure à 70%). C'est la **marge de sécurité vers le bas**.
 - calculer ainsi le plus petit nombre de sujets négatifs permettant de respecter cette contrainte, puis convertir ce nombre en effectif total selon la prévalence attendue de la NCB dans la population étudiée
- L'effectif total requis est calculé ainsi :

$$N_{total} = \frac{N_{negatifs}}{1 - p}$$

- (donc si la prévalence attendue est élevée, la proportion de patients négatifs est faible, et il faut inclure plus de patients pour avoir suffisamment de patients négatifs).
- Le protocole du CHU de Rennes prévoit 11 protocoles en faisant varier les spécificités cibles (85% ou 90%), les marges de sécurité (0.099 ou 0.149) et les prévalences attendues (50%, 60% ou 75%).
- Pour des raisons de validité de la méthode présentée ici, on recalcule manuellement tous les scénarios prévus par le protocole

```
sample_size_scenarios_input <- data.frame(
  S = paste0("S", 1:11),
  Scenario_num = 1:11,
  Sp_cible = c(
    0.90, 0.90, 0.90, 0.90, 0.90, 0.90,
    0.85, 0.85, 0.85, 0.85, 0.85
  ),
  p = c(
    0.75, 0.50, 0.75, 0.50, 0.60, 0.60,
```

```

    0.75, 0.50, 0.75, 0.60, 0.50
  ),
  Largeur_IC = c(
    0.099, 0.099, 0.149, 0.149, 0.099, 0.149,
    0.099, 0.099, 0.149, 0.099, 0.149
  )
)

sample_size_scenarios <- sample_size_scenarios_input %>%
crossing(N_negatifs_testes = 2:5000) %>%
mutate(
  Borne_inferieure = qbeta(
    0.05,
    N_negatifs_testes * Sp_cible,
    N_negatifs_testes * (1 - Sp_cible) + 1
  ),
  Largeur_calculée = Sp_cible - Borne_inferieure
) %>%
filter(Largeur_calculée <= Largeur_IC) %>%
group_by(Scenario_num) %>%
slice(1) %>%
ungroup() %>%
arrange(Scenario_num) %>%
transmute(
  S,
  Sp_cible,
  p,
  Largeur_IC,
  N_neg_requis = N_negatifs_testes,
  N_tot_requis = ceiling(N_negatifs_testes / (1 - p)),
  Borne_inferieure,
  Largeur_calculée
)

```

TABLE 1 – Effectif requis pour différents scénarios de spécificité cible, prévalence et marge

TABLE 2 – Tableau des effectifs requis pour les différents scénarios de spécificité cible, prévalence et marge de sécurité

Scenario	Target Sp	Prevalence	CI width	Required negatives	Required total N	Lower bound	Computed width
S1	0.90	0.75	0.099	50	200	0.801	0.099
S2	0.90	0.50	0.099	50	100	0.801	0.099
S3	0.90	0.75	0.149	27	108	0.751	0.149
S4	0.90	0.50	0.149	27	54	0.751	0.149
S5	0.90	0.60	0.099	50	125	0.801	0.099
S6	0.90	0.60	0.149	27	68	0.751	0.149
S7	0.85	0.75	0.099	59	236	0.752	0.098
S8	0.85	0.50	0.099	59	118	0.752	0.098
S9	0.85	0.75	0.149	31	124	0.704	0.146
S10	0.85	0.60	0.099	59	148	0.752	0.098
S11	0.85	0.50	0.149	31	62	0.704	0.146

4 Résultats des tests pris individuellement

4.A Caractéristiques initiales de la population

— Variables disponibles : Âge (`df$Age`), Sexe (`df$Sexe`), Côté (`df$Cote`), Niveau (`df$Niveau`)

4.A.1 Âge

TABLE 3 – variable âge

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
27	42.75	51	52.64815	58.75	125

— Un patient a 125 ans.

— Pour l’instant, la médiane de la population lui est attribuée.

```
#| label: age-corrige
#| echo: true
#| include: true
#| results: "hide"
# Remplacer l'âge de 125 ans par la médiane des âges
age_median <- median(df$Age, na.rm = TRUE)
df$Age <- ifelse(df$Age == 125, age_median, df$Age)
```

— Représentation de la variable âge après correction par histogramme avec densité et QQ-plot (le QQ plot se construit en comparant les quantiles de la variable âge à ceux d’une distribution normale théorique : si les points suivent une ligne droite, la variable suit une distribution normale).




FIGURE 1 – Distribution de l'âge

- L'âge semble suivre une distribution approximativement normale. Les tests statistiques de normalité (type Shapiro-Wilk) n'ont pas d'intérêt dans cette situation (permet uniquement de rejeter l'hypothèse de normalité si les données s'en écartent assez pour que le test ait la puissance nécessaire, or il n'y aura pas la puissance nécessaire avec seulement 50 patients).

4.A.2 Sexe

- Représentation de la variable sexe par un diagramme en barres et par un camembert (pie chart)




FIGURE 2 – Répartition du sexe

- Même si le camembert est plus visuel, le diagramme en barres est plus précis pour comparer les effectifs et les proportions (car affiche les effectifs totaux).

4.A.2.1 Côté

- Représentation de la variable côté par un diagramme en barres et par un camembert (pie chart)




FIGURE 3 – Répartition du côté

4.A.2.2 Niveau

- Représentation de la variable niveau par un diagramme en barres et par un camembert (pie chart)




FIGURE 4 – Répartition du niveau

4.A.2.3 Tableau de caractéristiques initiales

Caractéristiques	N = 54 ¹
Age	51 (42, 58)
Sexe	
Masculin	19 (35%)
Féminin	35 (65%)
Cote	
Gauche	25 (54%)
Droite	21 (46%)
Niveau	
C4	1 (4.2%)
C5	1 (4.2%)
C6	13 (54%)
C7	1 (4.2%)
C8	8 (33%)
Gold_Standard	
Douteux	3 (5.6%)
Negatif	14 (26%)
Positif	37 (69%)
U1_E1	
Negatif	14 (26%)
Positif	40 (74%)
U2a_E1	
Negatif	16 (30%)
Positif	38 (70%)
U2b_E1	
Negatif	19 (35%)
Positif	35 (65%)
U3_E1	
Negatif	33 (61%)
Positif	21 (39%)

¹Median (Q1, Q3) ; n (%)

— Échantillon total comprend 54 patients.

— Gold standard

— positif dans 37 cas (soit 68.5 %).

— douteux dans 3 cas (soit 5.6 %).

— négatif dans 17 cas (soit 31.5 %).

— Le premier point posé ici est la gestion des **Douteux** : ils sont d'abord tous reclassés comme négatifs, puis une analyse de sensibilité est réalisée en les reclassant comme positifs, pour évaluer l'impact de ce choix sur les résultats.

4.B Résultat des tests cliniques (test par test)

- La première partie de l'analyse est centrée sur les tests cliniques de l'évaluateur 1
- Elle évalue les performances "tests par tests"
- Une seconde partie agrège résultats et graphiques pour une comparaison globale des tests

4.B.1 ULNT1

- Résumé de la variable U1_E1

```
# tous les Gold_Standard "Douteux" sont interprétés comme "Negatif".
df$Gold_Standard_main <- ifelse(df$Gold_Standard == "Douteux", "Negatif", df$Gold_Standard)

# Garder uniquement les lignes avec Gold Standard binaire et U1 renseigné
u1_data <- df %>%
  filter(
    Gold_Standard_main %in% c("Positif", "Negatif"),
    !is.na(U1_E1)
  )

# Tableau de contingence
VP <- sum(u1_data$U1_E1 == "Positif" & u1_data$Gold_Standard_main == "Positif")
FN <- sum(u1_data$U1_E1 == "Negatif" & u1_data$Gold_Standard_main == "Positif")
FP <- sum(u1_data$U1_E1 == "Positif" & u1_data$Gold_Standard_main == "Negatif")
VN <- sum(u1_data$U1_E1 == "Negatif" & u1_data$Gold_Standard_main == "Negatif")

N <- VP + FN + FP + VN

# Sensibilité
Se <- VP / (VP + FN)
Se_IC <- binom.test(VP, VP + FN)$conf.int

# Spécificité
Sp <- VN / (VN + FP)
Sp_IC <- binom.test(VN, VN + FP)$conf.int

# Valeur prédictive positive
VPP <- VP / (VP + FP)
VPP_IC <- binom.test(VP, VP + FP)$conf.int

# Valeur prédictive négative
VPN <- VN / (VN + FN)
VPN_IC <- binom.test(VN, VN + FN)$conf.int

# Rapports de vraisemblance
LR_pos <- Se / (1 - Sp)
LR_neg <- (1 - Se) / Sp
```

```

# Indice de Youden
Youden <- Se + Sp - 1

# AUC descriptive
roc_u1 <- roc(
  response = as.numeric(u1_data$Gold_Standard_main == "Positif"),
  predictor = as.numeric(u1_data$U1_E1 == "Positif"),
  quiet = TRUE
)

AUC <- as.numeric(auc(roc_u1))
AUC_IC <- ci.auc(roc_u1)

# Test exact de Fisher
Fisher_p <- fisher.test(
  table(u1_data$U1_E1, u1_data$Gold_Standard_main)
)$p.value

```

TABLE 4 – Diagnostic performance of U1 compared with the reference standard

Test	N	VP	FN	FP	VN	Se	Se 95% CI	Sp	Sp 95% CI	PPV	PPV 95% CI	NPV	NPV 95% CI	LR+	LR-	Youden	AUC	AUC 95% CI	Fisher p
U1	54	31	6	9	8	0.838	[0.68 ; 0.938]	0.471	[0.23 ; 0.722]	0.775	[0.615 ; 0.892]	0.571	[0.289 ; 0.823]	1.58	0.34	0.308	0.654	[0.518 ; 0.791]	0.023

4.B.1.1 Tableaux récapitulatifs complémentaires

4.B.1.2 Tableau descriptif des résultats des tests

TABLE 5 – Tableau descriptif des résultats de U1 (évaluateur 1)

Test	Positif n (%)	Négatif n (%)	Manquant n (%)
U1	40 (74.1%)	14 (25.9%)	0 (0%)

4.B.1.3 Tableau de contingence avec le gold standard

TABLE 6 – Tableau de contingence de U1 par rapport au gold standard, avec effectifs et pourcentages sur l'ensemble des patients analysés

U1	G+	G-	Total
T+	31 (57.4%)	9 (16.7%)	40 (74.1%)
T-	6 (11.1%)	8 (14.8%)	14 (25.9%)
Total	37 (68.5%)	17 (31.5%)	54 (100%)

— T+/T- correspond à Test positif ou négatif, G+/G- correspond à Gold standard positif ou négatif.

4.B.1.4 Tableau des performances diagnostiques

TABLE 7 – Performances diagnostiques de U1 par rapport au gold standard

Test	N	VP	FN	FP	VN	Se	Sp	VPP	VPN	LR+	LR-	Youden	AUC	p Fisher
U1	54	31	6	9	8	0.838	0.471	0.775	0.571	1.58	0.34	0.308	0.654	0.023

Paramètres évalués :

- **LR = Likelihood ratio = Rapport de vraisemblance :**
 - Le **LR+** indique à quel point un test positif augmente la probabilité de maladie. Plus il est élevé et nettement supérieur à 1, plus un résultat positif renforce l'hypothèse diagnostique.
 - Le **LR-** indique à quel point un test négatif diminue la probabilité de maladie. Plus il est proche de 0, plus un résultat négatif aide à exclure la maladie.
 - **LR+** = 1.58 ; un test positif renforce très peu l'hypothèse diagnostique.
 - **LR-** = 0.34 ; un test négatif réduit modérément la probabilité de maladie, sans suffire à l'exclure à lui seul.
- **Indice de Youden** résume le compromis entre sensibilité et spécificité. Calcul = $Se + Sp - 1$ et varie indice de 0 (test non informatif) à 1 (test parfait).
 - Ici, U1 a un indice de Youden de 0.308 ; cela correspond à une performance diagnostique globale modeste.
- **AUC** : calculé à partir de la courbe ROC, l'aire sous la courbe (AUC) est une mesure globale de la capacité du test à discriminer entre les G+ et les G-.
 - Une AUC de 0.654 ; cela correspond à une discrimination faible à modérée.
- **Test exact de Fisher** : la p-value de 0.023 teste l'existence d'une association entre U1 et le gold standard. Une p-value faible suggère que la répartition des résultats du test diffère entre les patients G+ et G-, mais elle ne renseigne pas à elle seule sur l'ampleur clinique de cette utilité.
 - Ici, la p-value est inférieure à 0,05, ce qui suggère une association statistiquement significative entre U1 et le gold standard.

4.B.1.5 Courbe ROC




FIGURE 5 – Courbe ROC de U1 par rapport au gold standard

4.B.2 ULNT2a

```
# tous les Gold_Standard "Douteux" sont interprétés comme "Negatif".
df$Gold_Standard_main <- ifelse(df$Gold_Standard == "Douteux", "Negatif", df$Gold_Standard)

# Garder uniquement les lignes avec Gold Standard binaire et U1 renseigné
u2a_data <- df %>%
  filter(
    Gold_Standard_main %in% c("Positif", "Negatif"),
    !is.na(U2a_E1)
  )

# Tableau de contingence
VP <- sum(u2a_data$U2a_E1 == "Positif" & u2a_data$Gold_Standard_main == "Positif")
FN <- sum(u2a_data$U2a_E1 == "Negatif" & u2a_data$Gold_Standard_main == "Positif")
FP <- sum(u2a_data$U2a_E1 == "Positif" & u2a_data$Gold_Standard_main == "Negatif")
VN <- sum(u2a_data$U2a_E1 == "Negatif" & u2a_data$Gold_Standard_main == "Negatif")

N <- VP + FN + FP + VN

# Sensibilité
Se <- VP / (VP + FN)
Se_IC <- binom.test(VP, VP + FN)$conf.int

# Spécificité
```

```

Sp <- VN / (VN + FP)
Sp_IC <- binom.test(VN, VN + FP)$conf.int

# Valeur prédictive positive
VPP <- VP / (VP + FP)
VPP_IC <- binom.test(VP, VP + FP)$conf.int

# Valeur prédictive négative
VPN <- VN / (VN + FN)
VPN_IC <- binom.test(VN, VN + FN)$conf.int

# Rapports de vraisemblance
LR_pos <- Se / (1 - Sp)
LR_neg <- (1 - Se) / Sp

# Indice de Youden
Youden <- Se + Sp - 1

# AUC descriptive
roc_u2a <- roc(
  response = as.numeric(u2a_data$Gold_Standard_main == "Positif"),
  predictor = as.numeric(u2a_data$U2a_E1 == "Positif"),
  quiet = TRUE
)

AUC <- as.numeric(auc(roc_u2a))
AUC_IC <- ci.auc(roc_u2a)

# Test exact de Fisher
Fisher_p <- fisher.test(
  table(u2a_data$U2a_E1, u2a_data$Gold_Standard_main)
)$p.value

```

TABLE 8 – Diagnostic performance of U1 compared with the reference standard

Test	N	VP	FN	FP	VN	Se	Se 95% CI	Sp	Sp 95% CI	PPV	PPV 95% CI	NPV	NPV 95% CI	LR+	LR-	Youden	AUC	AUC 95% CI	Fisher p
U2a	54	29	8	9	8	0.784	[0.618; 0.902]	0.471	[0.23; 0.722]	0.763	[0.598; 0.886]	0.5	[0.247; 0.753]	1.48	0.46	0.254	0.627	[0.488; 0.767]	0.106

4.B.2.1 Tableaux récapitulatifs complémentaires

4.B.2.2 Tableau descriptif des résultats des tests

TABLE 9 – Tableau descriptif des résultats de U2a (évaluateur 1)

Test	Positifs n	Positifs %	Négatifs n	Négatifs %	Manquants n	Manquants %
U2a	38	70.4	16	29.6	0	0

4.B.2.3 Tableau de contingence avec le gold standard

TABLE 10 – Tableau de contingence de U2a par rapport au gold standard, avec effectifs et pourcentages sur l'ensemble des patients analysés

U2a	G+	G-	Total
T+	29 (53.7%)	9 (16.7%)	38 (70.4%)
T-	8 (14.8%)	8 (14.8%)	16 (29.6%)
Total	37 (68.5%)	17 (31.5%)	54 (100%)

— T+/T- correspond à Test positif ou négatif, G+/G- correspond à Gold standard positif ou négatif.

4.B.2.4 Tableau des performances diagnostiques

TABLE 11 – Performances diagnostiques de U2a par rapport au gold standard

Test	N	VP	FN	FP	VN	Se	Sp	VPP	VPN	LR+	LR-	Youden	AUC	p Fisher
U2a	54	29	8	9	8	0.784	0.471	0.763	0.5	1.48	0.46	0.254	0.627	0.106

Paramètres évalués :

— **LR = Likelihood ratio = Rapport de vraisemblance :**

— **LR+** = 1.48 ; un test positif renforce très peu l'hypothèse diagnostique.

— **LR-** = 0.46 ; un test négatif réduit modérément la probabilité de maladie, sans suffire à l'exclure à lui seul.

— **Indice de Youden**

— Ici, U2a a un indice de Youden de 0.254 ; cela correspond à une performance diagnostique globale modeste.

— **AUC :**

— Une AUC de 0.627 ; cela correspond à une discrimination faible à modérée.

— **Test exact de Fisher :** la p-value de 0.106 teste l'existence d'une association entre U2a et le gold standard.

- Ici, la p-value n'est pas inférieure à 0,05, ce qui ne permet pas de conclure à une association statistiquement significative entre U2a et le gold standard.

4.B.2.5 Courbe ROC




FIGURE 6 – Courbe ROC de U2a par rapport au gold standard

4.B.3 ULNT2b

4.B.3.1 Tableau descriptif des résultats des tests

TABLE 12 – Tableau descriptif des résultats de U2b (évaluateur 1)

Test	Positifs n	Positifs %	Négatifs n	Négatifs %	Manquants n	Manquants %
U2b	35	64.8	19	35.2	0	0

4.B.3.2 Tableau de contingence avec le gold standard

TABLE 13 – Tableau de contingence de U2b par rapport au gold standard, avec effectifs et pourcentages sur l'ensemble des patients analysés

U2b	G+	G-	Total
T+	28 (51.9%)	7 (13%)	35 (64.8%)
T-	9 (16.7%)	10 (18.5%)	19 (35.2%)
Total	37 (68.5%)	17 (31.5%)	54 (100%)

- T+/T- correspond à Test positif ou négatif, G+/G- correspond à Gold standard positif ou négatif.

4.B.3.3 Tableau des performances diagnostiques

TABLE 14 – Performances diagnostiques de U2b par rapport au gold standard

Test	N	VP	FN	FP	VN	Se	Sp	VPP	VPN	LR+	LR-	Youden	AUC	P Fisher
U2b	54	28	9	7	10	0.757	0.588	0.8	0.526	1.84	0.41	0.345	0.672	0.0297

Paramètres évalués :

- **LR = Likelihood ratio = Rapport de vraisemblance :**
 - **LR+** = 1.84 ; un test positif renforce très peu l’hypothèse diagnostique.
 - **LR-** = 0.41 ; un test négatif réduit modérément la probabilité de maladie, sans suffire à l’exclure à lui seul.
- **Indice de Youden**
 - Ici, **U2b** a un indice de Youden de 0.345 ; cela correspond à une performance diagnostique globale modeste.
- **AUC :**
 - Une AUC de 0.672 ; cela correspond à une discrimination faible à modérée.
- **Test exact de Fisher :** la p-value de 0.0297 teste l’existence d’une association entre **U2b** et le gold standard.
 - Ici, la p-value est inférieure à 0,05, ce qui suggère une association statistiquement significative entre **U2b** et le gold standard.

4.B.3.4 Courbe ROC




FIGURE 7 – Courbe ROC de U2b par rapport au gold standard

4.B.4 ULNT3

4.B.4.1 Tableau descriptif des résultats des tests

TABLE 15 – Tableau descriptif des résultats de U3 (évaluateur 1)

Test	Positifs n	Positifs %	Négatifs n	Négatifs %	Manquants n	Manquants %
U3	21	38.9	33	61.1	0	0

4.B.4.2 Tableau de contingence avec le gold standard

TABLE 16 – Tableau de contingence de U3 par rapport au gold standard, avec effectifs et pourcentages sur l'ensemble des patients analysés

U3	G+	G-	Total
T+	14 (25.9%)	7 (13%)	21 (38.9%)
T-	23 (42.6%)	10 (18.5%)	33 (61.1%)
Total	37 (68.5%)	17 (31.5%)	54 (100%)

— T+/T- correspond à Test positif ou négatif, G+/G- correspond à Gold standard positif ou négatif.

4.B.4.3 Tableau des performances diagnostiques

TABLE 17 – Performances diagnostiques de U3 par rapport au gold standard

Test	N	VP	FN	FP	VN	Se	Sp	VPP	VPN	LR+	LR-	Youden	AUC	p Fisher
U3	54	14	23	7	10	0.378	0.588	0.667	0.303	0.92	1.06	- 0.033	0.483	1

Paramètres évalués :

— **LR = Likelihood ratio = Rapport de vraisemblance :**

— **LR+** = 0.92 ; un test positif ne renforce pas l'hypothèse diagnostique et peut même orienter légèrement dans le sens inverse.

— **LR-** = 1.06 ; un test négatif n'aide pas à exclure la maladie et peut même aller légèrement dans le sens inverse.

— **Indice de Youden**

— Ici, U3 a un indice de Youden de -0.033 ; cela traduit un test globalement non informatif dans cet échantillon.

— **AUC :**

— Une AUC de 0.483 ; cela signifie que le test discrimine moins bien que le hasard dans cette cohorte.

— **Test exact de Fisher :** la p-value de 1 teste l'existence d'une association entre U3 et le gold standard.

— Ici, la p-value n'est pas inférieure à 0,05, ce qui ne permet pas de conclure à une association statistiquement significative entre U3 et le gold standard.

4.B.4.4 Courbe ROC




FIGURE 8 – Courbe ROC de U3 par rapport au gold standard

4.C Résultats globaux résumés

4.C.1 Tableau de contingence global

TABLE 18 – Tableau global de contingence des ULNT par rapport au gold standard

Test	VP	FN	FP	VN	N
U1	31	6	9	8	54
U2a	29	8	9	8	54
U2b	28	9	7	10	54
U3	14	23	7	10	54

4.C.2 Tableau global des performances diagnostiques

TABLE 19 – Tableau global des performances diagnostiques des ULNT

Test	N	Se	Sp	VPP	VPN	LR+	LR-	Youden	AUC	p Fisher
U1	54	0.838	0.471	0.775	0.571	1.58	0.34	0.308	0.654	0.0230
U2a	54	0.784	0.471	0.763	0.500	1.48	0.46	0.254	0.627	0.1060
U2b	54	0.757	0.588	0.800	0.526	1.84	0.41	0.345	0.672	0.0297
U3	54	0.378	0.588	0.667	0.303	0.92	1.06	-0.033	0.483	1.0000




FIGURE 9 – Composition des tableaux de contingence 2x2 par test




FIGURE 10 – Comparaison des courbes ROC des ULNT

Interprétation des résultats

Les tests U1, U2a et U2b ont une sensibilité modérée à élevée, surtout U1 ($Se = 0.838$), mais leur spécificité reste faible à moyenne ($Sp = 0.471-0.588$), ce qui limite leur capacité à confirmer formellement le diagnostic.

U2b présente le meilleur compromis global avec le Youden le plus élevé (0.345), l'AUC la plus haute (0.672) et le meilleur $LR+$ (1.84), mais ses performances restent modestes.

U3 ne discrimine pas mieux que le hasard dans cet échantillon ($AUC = 0.483$, Youden négatif, $p = 1.000$) et ne semble pas utile diagnostiquement ici.

En pratique : Globalement, les ULNT ont une sensibilité correcte pour U1, U2a et U2b, mais une spécificité faible à modérée, ce qui signifie qu'ils détectent assez souvent les patients positifs mais génèrent aussi beaucoup de faux positifs. U2b semble le meilleur compromis global avec le Youden le plus élevé, la meilleure AUC et le meilleur $LR+$, même si la performance reste modeste.

Ces tests peuvent surtout servir comme outils d'orientation ou de dépistage, en particulier U1/U2b, mais ils ne suffisent pas à confirmer formellement le diagnostic. Un test négatif, surtout pour U1 avec un $LR-$ à 0,34, peut réduire la probabilité de NCB, mais aucun ULNT

ne paraît assez discriminant pour être utilisé isolément sans confrontation au contexte clinique et aux autres examens.

4.D Résultats par niveaux métamériques

On calcule ici uniquement les taux de positivité par niveau métamérique (c'est à dire la proportion de tests positifs parmi les tests réalisés à chaque niveau, chez les patients ayant un résultat

Section **descriptive** : données par niveau métamérique sont trop pauvres pour une conclusion statistique valide : - C4, C5 et C7 n'ont qu'un seul dossier chacun. - C8 n'a que 8 dossiers exploitables pour U1.

Ça se voit très bien sur un graphique sur lequel on met l'effectif en ordonnée :

4.D.1 Performance diagnostique par niveau métamérique

Cette section complète les graphes descriptifs précédents en regardant non plus seulement la fréquence de positivité des tests, mais leurs **performances diagnostiques par niveau métamérique** par rapport au gold standard. Vu les effectifs très faibles à plusieurs niveaux, cette lecture doit rester **strictement exploratoire**.

TABLE 20 – Performances diagnostiques exploratoires des ULNT selon le niveau métamérique

Niveau	Test	N	G_pos	G_neg	Se	Sp	VPP	VPN	LR+	LR-	Youden	AUC	P Fisher
C4	U1	1	1	0	0.0	NA	NA	0.000	NA	NA	NA	NA	NA
C5	U1	1	0	1	NA	1.000	NA	1.000	NA	NA	NA	NA	NA
C6	U1	13	10	3	0.9	0.000	0.750	0.000	0.9	NA	- 0.100	0.450	1.000
C7	U1	1	0	1	NA	0.000	0.000	NA	NA	NA	NA	NA	NA
C8	U1	8	5	3	0.8	0.667	0.800	0.667	2.4	0.3	0.467	0.733	0.464
C4	U2a	1	1	0	0.0	NA	NA	0.000	NA	NA	NA	NA	NA
C5	U2a	1	0	1	NA	1.000	NA	1.000	NA	NA	NA	NA	NA
C6	U2a	13	10	3	0.8	0.000	0.727	0.000	0.8	NA	- 0.200	0.400	1.000
C7	U2a	1	0	1	NA	0.000	0.000	NA	NA	NA	NA	NA	NA
C8	U2a	8	5	3	0.4	0.667	0.667	0.400	1.2	0.9	0.067	0.533	1.000
C4	U2b	1	1	0	0.0	NA	NA	0.000	NA	NA	NA	NA	NA
C5	U2b	1	0	1	NA	1.000	NA	1.000	NA	NA	NA	NA	NA
C6	U2b	13	10	3	0.6	0.000	0.667	0.000	0.6	NA	- 0.400	0.300	0.497
C7	U2b	1	0	1	NA	0.000	0.000	NA	NA	NA	NA	NA	NA
C8	U2b	8	5	3	0.6	0.667	0.750	0.500	1.8	0.6	0.267	0.633	1.000
C4	U3	1	1	0	0.0	NA	NA	0.000	NA	NA	NA	NA	NA
C5	U3	1	0	1	NA	1.000	NA	1.000	NA	NA	NA	NA	NA
C6	U3	13	10	3	0.2	0.333	0.500	0.111	0.3	2.4	- 0.467	0.733	0.203
C7	U3	1	0	1	NA	0.000	0.000	NA	NA	NA	NA	NA	NA

Niveau	Test	N	G_pos	G_neg	Se	Sp	VPP	VPN	LR+	LR-	Youden	AUC	p Fisher
C8	U3	8	5	3	0.0	0.667	0.000	0.286	0.0	1.5	-	0.333	0.375




FIGURE 11 – Heatmap exploratoire des performances diagnostiques selon le niveau métamérique

Lecture pratique : ici, le bon dénominateur n'est plus "tous les tests positifs observés à un niveau", mais bien le **gold standard** à ce niveau. Ainsi, la sensibilité correspond à la proportion de patients G+ correctement détectés par le test, et la spécificité à la proportion de patients G- correctement classés négatifs. Cela répond mieux à la question de la **performance diagnostique** selon le niveau métamérique. En revanche, avec plusieurs niveaux n'ayant qu'1 à 13 dossiers seulement, ces estimations sont très instables et ne doivent pas être surinterprétées.

TABLE 21 – Inter-observer agreement for each ultrasound test

Test	N	Accord	Kappa	IC95% bas	IC95% haut	Interpretation
U1	52	0.865	0.611	0.353	0.869	substantielle
U2a	52	0.808	0.532	0.279	0.786	moderee
U2b	52	0.788	0.512	0.261	0.763	moderee
U3	52	0.808	0.607	0.389	0.825	substantielle

4.E Reproductibilité inter-évaluateurs




FIGURE 12 – Kappa inter-observer agreement for each ultrasound test.

Le Kappa de Cohen correspond à la concordance corrigée, c'est à dire le pourcentage d'accord entre les évaluateurs corrigé par le taux d'accord attendu par hasard.

Interprétation selon tableau de Landis & Koch (1977) : - < 0 : pas d'accord - 0.00–0.20 : accord faible - 0.21–0.40 : accord passable - 0.41–0.60 : accord modéré - 0.61–0.80 : accord substantiel - 0.81–1.00 : accord presque parfait

5 Résultats des tests en les combinant

2 façons de combiner les tests :

- Soit sans les départager : calcul de la probabilité de NCB en fonction du nombre de tests positifs (de 0 à 4)
- Soit en les départageant : calcul de la probabilité de NCB en fonction du test le plus distal positif (U1, U2a, U2b ou U3)


5.A Probabilité de NCB en fonction du nombre de tests positifs

TABLE 22

TABLE 23 – Probabilité observée de NCB selon le nombre exact de tests positifs

Nombre de tests positifs	Effectif (N)	Nombre de NCB	Probabilité de NCB [IC95%]
0	9	2	0.222 [0.028 ; 0.6]
1	4	3	0.75 [0.194 ; 0.994]
2	8	7	0.875 [0.473 ; 0.997]
3	18	15	0.833 [0.586 ; 0.964]
4	15	10	0.667 [0.384 ; 0.882]

Probabilité observée de NCB selon le nombre de tests positifs



Points : probabilité observée de NCB pour chaque nombre de tests positifs. Barres d'erreur : IC95% de cette probabilité.

FIGURE 13 – Probabilité observée de NCB selon le nombre de tests positifs.

5.B Score de positivité : performances diagnostiques selon les seuils de score

L'objectif ici est de calculer les performances diagnostiques (sensibilité, spécificité, LR+, LR-, DOR) pour différents seuils de score (≥ 1 positif, ≥ 2 positifs, ≥ 3 positifs, ≥ 4 positifs). Cela permet d'évaluer comment la performance diagnostique évolue en fonction du nombre de tests positifs.

En gros, ça servirait à dire "considérer le diagnostic positif de NCB si au moins 2 tests sont positifs" a eu une sensibilité de X% et une spécificité de Y% dans cet échantillon, etc.

DOR = différence d'Odds Ratio entre les patients positifs et négatifs : $(VP/VN) / (FP/FN) = (VP\,VN) / (FP\,FN)$. Plus le DOR est élevé, meilleure est la performance diagnostique du test.

TABLE 24 – Performances diagnostiques selon le seuil du score

Seuil	Se	Sp	LR+	LR-	DOR
≥ 1 positif	0.946	0.412	1.608	0.131	12.250
≥ 2 positifs	0.865	0.471	1.634	0.287	5.689
≥ 3 positifs	0.676	0.529	1.436	0.613	2.344
≥ 4 positifs	0.270	0.706	0.919	1.034	0.889

Références