

Stats Thèse Briec

Thomas Husson

Table des matières

1	Import de la base et préparation des données	3
2	Introduction	3
3	Conformité au protocole de la méthodologiste	3
4	Méthodes	4
4.A	Patients	4
4.B	Procédures	4
4.C	Critères de jugement	4
4.D	Analyse statistique	4
5	Disclaimer : nombre de sujets nécessaires et précision attendue	6
6	Résultats	8
6.A	Population analysée	8
6.B	Performances test par test	15
6.C	Synthèse globale des tests	20
6.D	Comparaisons directes entre tests	23
6.E	Reproductibilité inter-évaluateurs	23
6.F	Combinaisons et score de positivité ULNT	25
6.G	Analyses exploratoires par niveau métamérique	28

i Origine de ce document

- Ce document est au format Quarto Markdown (.qmd) : il contient du code R et est généré directement pour obtenir un rapport en PDF ou HTML.
- Il est donc à la fois un document de travail pour moi, et à la fois un document de présentation des analyses. Je laisse donc volontairement les sections de code pour transparence et reproductibilité des analyses.
- La préparation des données a été faite sur R plutôt que sur Excel pour éviter les erreurs et tracer les étapes. La première partie du document est donc consacrée à la préparation des données, avec des sections de code pour chaque variable (vous pouvez donc sauter les sections de code si vous ne souhaitez pas les détails de la préparation des données).
- Je suis interne en chirurgie digestive à Paris et actuellement un master 2 en biostatistiques (“Méthodologie et Statistiques en Recherche biomédicale”, Université Paris Saclay). Et accessoirement, ami de Briec !
- Le rapport est disponible en format HTML hébergé sur Github Pages, et aussi téléchargeable en PDF, DOCX et Quarto (.qmd), contenant le code R utilisé pour les analyses.

1 Import de la base et préparation des données

2 Introduction

- 4 tests ULNT (Upper Limb Neurodynamic Tests) : ULNT1, ULNT2a, ULNT2b, ULNT3
- Évaluation de la performance diagnostique de ces tests pour le diagnostic des névralgies cervico-brachiales (NCB) en consultation de chirurgie orthopédique, par rapport à un gold standard principal basé sur l'examen clinique + IRM.

3 Conformité au protocole de la méthodologiste

Les points du protocole couverts sont :

- la description de la population ;
- les performances diagnostiques des tests individuels avec IC95 ;
- les comparaisons directes entre ULNT sur données appariées ;
- la reproductibilité inter-évaluateurs ;
- l'exploration des combinaisons de tests ;
- la lecture exploratoire selon le niveau métamérique, y compris **test par test**.

2 divergences :

- restriction aux 4 ULNT (pas de Scratch Collapse Test)
- pour les gold standard, le second gold standard prévu initialement impliquait la réponse à l'infiltration. Ici, 26 patients ont eu une infiltration, et 24 patients ont des résultats renseignés. On utilise donc la colonne **Gold Standard**

4 Méthodes

4.A Patients

Les données ont été recueillies de manière prospective au CHU de Rennes. Les patients adultes adressés pour une première consultation de chirurgie orthopédique du rachis pour suspicion de névralgie cervico-brachiale ont été inclus dans une base de données dédiée. L'analyse présentée dans ce rapport a porté sur les patients pour lesquels le gold standard principal était renseigné et interprétable dans la base analysée. Dans cette version du recueil, la variable **Gold Standard** ne comportait que deux modalités, **Positif** et **Négatif**, correspondant respectivement à la présence ou à l'absence de névralgie cervico-brachiale selon le gold standard principal.

xxxx

4.B Procédures

4 tests xxxx

4.C Critères de jugement

Critère de jugement principal

Le critère de jugement principal était la performance diagnostique des quatre ULNT pour le diagnostic de névralgie cervico-brachiale, par rapport au gold standard principal. Ce critère reposait sur l'estimation, pour chaque test, de la sensibilité, de la spécificité, des valeurs prédictives positive et négative, ainsi que des rapports de vraisemblance positif et négatif.

4.C.1 Critères de jugement secondaires

Les critères de jugement secondaires comprenaient la comparaison appariée des performances diagnostiques entre ULNT, la reproductibilité inter-évaluateurs entre l'évaluateur 1 et l'évaluateur 2, les performances diagnostiques des combinaisons conjonctives de tests, l'analyse du score global de positivité ULNT et de ses seuils, ainsi qu'une exploration des performances selon le niveau métamérique.

4.D Analyse statistique

Les variables qualitatives ont été décrites par leurs effectifs et pourcentages. Les variables quantitatives ont été décrites par des paramètres de position et de dispersion adaptés à leur distribution. Les données manquantes n'ont pas été imputées.

Les performances diagnostiques des quatre ULNT réalisés par l'évaluateur 1 ont été évaluées par rapport au gold standard principal. Pour chaque test, des tableaux de contingence 2 x 2 ont permis d'estimer la sensibilité, la spécificité, les valeurs prédictives positive et négative, les rapports de vraisemblance positif et négatif, l'indice de Youden et l'aire sous la courbe ROC. Les intervalles de confiance à 95 % des proportions ont été calculés par la méthode binomiale exacte de Clopper-Pearson. L'association entre chaque ULNT et le gold standard principal a été étudiée par le test exact de Fisher.

Les performances des différents ULNT ont été comparées entre elles à l'aide du test de McNemar (χ^2 pour données appariées). La reproductibilité inter-évaluateurs a été évaluée par le coefficient

kappa de Cohen.

Des analyses complémentaires ont porté sur les combinaisons de tests et sur le score global de positivité ULNT, défini comme le nombre total d'ULNT positifs chez un même patient. Les combinaisons conjonctives possibles des quatre ULNT ont été explorées. Le score global a été étudié selon différents seuils de positivité, puis modélisé par régression logistique binaire afin d'évaluer son association avec la probabilité de névralgie cervico-brachiale.

Des analyses exploratoires ont également été réalisées selon le niveau métamérique. Pour chaque niveau, la performance de chaque ULNT a été évaluée ainsi que l'association entre le niveau métamérique et la probabilité de névralgie cervico-brachiale. Une régression logistique a ensuite été utilisée pour évaluer l'association entre le niveau métamérique, le score global de positivité ULNT et la probabilité de névralgie cervico-brachiale.

Les résultats sont présentés sous forme d'estimations ponctuelles avec leurs intervalles de confiance à 95 %. Les modèles logistiques sont présentés sous forme d'odds ratios lorsque cela était pertinent. Les analyses ont été réalisées avec R, version 4.5.2. Tous les tests étaient bilatéraux, avec un seuil de significativité fixé à 0,05. Aucune correction de multiplicité n'a été appliquée aux analyses secondaires ou exploratoires, qui doivent donc être interprétées comme génératrices d'hypothèses.

5 Disclaimer : nombre de sujets nécessaires et précision attendue

Le protocole du CHU de Rennes prévoyait initialement un raisonnement de dimensionnement basé sur la **spécificité**, à partir d’intervalles de confiance exact de Clopper-Pearson. Cette logique faisait varier la spécificité cible, la marge acceptable entre cette cible et la borne inférieure de l’IC95 %, ainsi que la prévalence attendue de la NCB.

11 scénarios théoriques étaient proposés, et sont recalculés ici :

TABLE 1 – Effectif requis pour différents scénarios de spécificité cible, prévalence et marge

Scenario	Target Sp	Prevalence	CI width	Required negatives	Required total N	Lower bound	Computed width
S1	0.90	0.75	0.099	50	200	0.801	0.099
S2	0.90	0.50	0.099	50	100	0.801	0.099
S3	0.90	0.75	0.149	27	108	0.751	0.149
S4	0.90	0.50	0.149	27	54	0.751	0.149
S5	0.90	0.60	0.099	50	125	0.801	0.099
S6	0.90	0.60	0.149	27	68	0.751	0.149
S7	0.85	0.75	0.099	58	232	0.751	0.099
S8	0.85	0.50	0.099	58	116	0.751	0.099
S9	0.85	0.75	0.149	30	120	0.701	0.149
S10	0.85	0.60	0.099	58	145	0.751	0.099
S11	0.85	0.50	0.149	30	60	0.701	0.149

En prenant en compte ce tableau, le choix d’arrêter les inclusions peut poser question : le nombre de sujets négatifs minimal nécessaire pour atteindre la précision visée par “le pire scénario” prévue par la méthodologiste n’est pas acquis. Il faudrait 27 cas négatifs sur un effectif total de 68 patients pour cibler une spécificité de 0,90 avec une marge de 0,149 et une prévalence de 60 %.

Or, dans la cohorte analysée, nous avons 24 cas négatifs sur un effectif total de 69 patients, soit une prévalence de NCB de 65.2 %.

Le nombre total de patients est suffisant, mais le nombre de patients négatifs est légèrement inférieur à ce qui était prévu pour atteindre la précision visée sur la spécificité.

Quel impact ?

- Dans le scénario le plus proche du protocole :
 - Spécificité cible : 0,90
 - Marge de précision prévue (différence entre la spécificité cible et la borne inférieure de l’IC95%) : 0,149
 - Prévalence attendue : 60 %
 - Effectif total requis : 68 patients
 - Effectif négatif requis : 27 patients
- Dans la cohorte analysée :
 - Effectif total : 69 patients
 - Effectif négatif : 24 patients
 - Prévalence observée : 65.2 %
 - Spécificité observée pour la combinaison de tests la plus spécifique : 0.792, avec un IC95% de [0.578 ; 0.929]
 - Marge de précision observée pour la spécificité : 0.213, donc supérieure à la marge

de précision prévue de 0,149

Ce que je propose : faire comme si la méthodologiste n'avait jamais calculé de nombre de sujets requis (parce que sinon, pourquoi avoir arrêté les inclusions avant d'avoir le nombre requis de patients négatifs?)

6 Résultats

6.A Population analysée

- Variables disponibles : Âge (`df$Age`), Sexe (`df$Sexe`), Côté (`df$Cote`), Niveau (`df$Niveau`), BMI (`df$BMI`), Tabac (`df$Tabac`), Infiltrations (`df$Infiltrations`), Résultat des infiltrations (`df$Resultat_Inf`)

6.A.1 Âge

TABLE 2 – variable âge

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
27	45	51	52	59	77

- Représentation de la variable âge par histogramme avec densité et QQ-plot (le QQ plot se construit en comparant les quantiles de la variable âge à ceux d’une distribution normale théorique : si les points suivent une ligne droite, la variable suit une distribution normale).




FIGURE 1 – Distribution de l'âge

- L'âge semble suivre une distribution approximativement normale. Les tests statistiques de normalité (type Shapiro-Wilk) ont ici un intérêt limité : avec 69 patients, ils peuvent manquer de puissance pour détecter des écarts modestes, tandis que l'inspection graphique reste plus informative.

6.A.2 Sexe




FIGURE 2 – Répartition du sexe

— Même si le camembert est plus visuel, le diagramme en barres est plus précis pour comparer les effectifs et les proportions (car affiche les effectifs totaux).

6.A.2.1 Côté




FIGURE 3 – Répartition du côté

6.A.2.2 Niveau




FIGURE 4 – Répartition du niveau

6.A.2.3 BMI

TABLE 3 – Variable BMI

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.	NA's
17	22.75	25	26.4375	30	45	5

— Le BMI est renseigné chez 64 patients sur 69.




FIGURE 5 – Distribution du BMI

6.A.2.4 Tabac

TABLE 4 – Répartition du tabac

Modalite	Effectif	Pourcentage
Non	37	57.8
Oui	27	42.2

— Le statut tabagique est renseigné chez 64 patients sur 69.




FIGURE 6 – Répartition du tabac

6.A.2.5 Infiltrations

TABLE 5 – Répartition du statut d'infiltration

Modalite	Effectif	Pourcentage
Non	42	61.8
Oui	26	38.2

— Le statut d'infiltration est interprétable chez 68 patients sur 69.




FIGURE 7 – Répartition du statut d'infiltration

6.A.2.6 Résultat des infiltrations

TABLE 6 – Répartition du résultat des infiltrations

Modalite	Effectif	Pourcentage
Negatif	5	20.8
Positif	19	79.2

— Parmi les 26 patients ayant eu une infiltration, le résultat est renseigné chez 24.




FIGURE 8 – Répartition du résultat des infiltrations

6.A.2.7 Tableau de caractéristiques initiales

Caractéristiques	N = 69 ^t
Âge (années)	51 (45, 59)
BMI (kg/m ²)	25.0 (22.5, 30.0)
Sexe	
Masculin	23 (33%)
Féminin	46 (67%)
Côté	
Gauche	35 (51%)
Droite	34 (49%)
Niveau	
C4	1 (1.4%)
C5	10 (14%)
C6	27 (39%)
C7	21 (30%)
C8	10 (14%)
Tabac actif	27 (42%)
Infiltrations	26 (38%)
Résultat des infiltrations	19 (79%)
Gold Standard positif	45 (65%)
ULNT1 E1 positif	48 (70%)
ULNT2a E1 positif	46 (67%)
ULNT2b E1 positif	39 (57%)
ULNT3 E1 positif	25 (36%)

^tMedian (Q1, Q3) ; n (%)

6.B Performances test par test

- La première partie de l'analyse est centrée sur les tests cliniques de l'évaluateur 1
- Elle évalue les performances “tests par tests”
- Une seconde partie agrège résultats et graphiques pour une comparaison globale des tests

6.B.1 ULNT1

6.B.1.1 Résultats

TABLE 7 – Tableau descriptif des résultats de U1 (évaluateur 1)

Test	Positif n (%)	Négatif n (%)
U1	48 (69.6%)	21 (30.4%)

TABLE 8 – Tableau de contingence de U1 par rapport au gold standard

U1	G+	G-	Total
T+	39 (56.5%)	9 (13%)	48 (69.6%)
T-	6 (8.7%)	15 (21.7%)	21 (30.4%)
Total	45 (65.2%)	24 (34.8%)	69 (100%)

- T+/T- correspond à Test positif ou négatif, G+/G- correspond au Gold standard

TABLE 9 – Effectifs diagnostiques de U1 par rapport au gold standard

Test	N	VP	FN	FP	VN
U1	69	39	6	9	15

TABLE 10 – Performances diagnostiques de U1 par rapport au gold standard

Test	Se [IC95]	Sp [IC95]	VPP [IC95]	VPN [IC95]	LR+	LR-	Youden	AUC [IC95]
U1	0.867 [0.732 ; 0.949]	0.625 [0.406 ; 0.812]	0.812 [0.674 ; 0.911]	0.714 [0.478 ; 0.887]	2.31	0.21	0.492	0.746 [0.635 ; 0.857]

6.B.1.2 Interprétation

- Lecture des résultats :
 - Sensibilité : parmi les patients avec NCB, combien ont un test positif
 - Spécificité : parmi les patients sans NCB, combien ont un test
 - VPP : parmi les patients avec un test positif, combien ont une NCB
 - VPN : parmi les patients avec un test négatif, combien n'ont pas de
 - LR+ : combien un test positif augmente la probabilité de NCB
 - LR- : combien un test négatif diminue la probabilité de NCB

- Youden : mesure globale de performance ($Se + Sp - 1$)
- AUC : mesure globale de performance (AUC de la courbe ROC). Pas vraiment un bon indicateur pour un test binaire.
- Interprétation :
 - Sensibilité excellente (0.864) : repère bien les patients avec NCB
 - LR- très bon (0.23) : un test négatif rend la NCB moins probable (utile surtout pour statistiques bayésiennes : probabilité post-test = probabilité pré-test x LR-). Donc si la probabilité pré-test est modérée, un test négatif divise la probabilité par 4 environ.

6.B.2 ULNT2a

6.B.2.1 Résultats

TABLE 11 – Tableau descriptif des résultats de U2a (évaluateur 1)

Test	Positifs n	Positifs %	Négatifs n	Négatifs %
U2a	46	66.7	23	33.3

6.B.2.2 Tableau de contingence avec le gold standard

TABLE 12 – Tableau de contingence de U2a par rapport au gold standard, avec effectifs et pourcentages sur l'ensemble des patients analysés

U2a	G+	G-	Total
T+	36 (52.2%)	10 (14.5%)	46 (66.7%)
T-	9 (13%)	14 (20.3%)	23 (33.3%)
Total	45 (65.2%)	24 (34.8%)	69 (100%)

— T+/T- correspond à Test positif ou négatif, G+/G- correspond à Gold standard positif ou négatif.

6.B.2.3 Tableau des effectifs diagnostiques

TABLE 13 – Effectifs diagnostiques de U2a par rapport au gold standard

Test	N	VP	FN	FP	VN
U2a	69	36	9	10	14

6.B.2.4 Tableau des performances diagnostiques

TABLE 14 – Performances diagnostiques de U2a par rapport au gold standard

Test	Se [IC95]	Sp [IC95]	VPP [IC95]	VPN [IC95]	LR+	LR-	Youden	AUC [IC95]
U2a	0.8 [0.654 ; 0.904]	0.583 [0.366 ; 0.779]	0.783 [0.636 ; 0.891]	0.609 [0.385 ; 0.803]	1.92	0.34	0.383	0.692 [0.575 ; 0.808]

Lecture simple

Ce qu'on cherche. Ici, on cherche à savoir si U2a peut jouer le même rôle que U1, c'est-à-dire détecter une partie importante des NCB tout en limitant les erreurs chez les patients sans NCB.

Comment lire ce résultat. Il faut surtout regarder le compromis entre sensibilité et spécificité, puis les rapports de vraisemblance. Plus le LR+ est élevé, plus un positif renforce l'hypothèse de NCB. Plus le LR- est proche de 0, plus un négatif aide à écarter la maladie.

Ce que montrent les données ici. U2a a Se 0.795, Sp 0.56, VPP 0.761, VPN 0.609, LR+ 1.81, LR- 0.37, Youden 0.355 et AUC 0.678. Il reste plutôt sensible, donc il détecte encore une part importante des cas, mais il est moins convaincant que U1. Sa spécificité est modeste, ce qui veut dire qu'il garde un nombre notable de faux positifs. Son LR- aide un peu quand le test est négatif, mais clairement moins que celui de U1.

Application pratique. U2a est utile comme argument supplémentaire dans le raisonnement clinique, mais il paraît moins solide que U1 pour servir de pivot. En pratique, il complète bien l'examen, sans justifier à lui seul une décision diagnostique.

6.B.3 ULNT2b

6.B.3.1 Tableau descriptif des résultats des tests

TABLE 15 – Tableau descriptif des résultats de U2b (évaluateur 1)

Test	Positifs n	Positifs %	Négatifs n	Négatifs %
U2b	39	56.5	30	43.5

6.B.3.2 Tableau de contingence avec le gold standard

TABLE 16 – Tableau de contingence de U2b par rapport au gold standard, avec effectifs et pourcentages sur l'ensemble des patients analysés

U2b	G+	G-	Total
T+	31 (44.9%)	8 (11.6%)	39 (56.5%)
T-	14 (20.3%)	16 (23.2%)	30 (43.5%)
Total	45 (65.2%)	24 (34.8%)	69 (100%)

— T+/T- correspond à Test positif ou négatif, G+/G- correspond à Gold standard positif ou négatif.

6.B.3.3 Tableau des effectifs diagnostiques

TABLE 17 – Effectifs diagnostiques de U2b par rapport au gold standard

Test	N	VP	FN	FP	VN
U2b	69	31	14	8	16

6.B.3.4 Tableau des performances diagnostiques

TABLE 18 – Performances diagnostiques de U2b par rapport au gold standard

Test	Se [IC95]	Sp [IC95]	VPP [IC95]	VPN [IC95]	LR+	LR-	Youden	AUC [IC95]
U2b	0.689 [0.534 ; 0.818]	0.667 [0.447 ; 0.844]	0.795 [0.635 ; 0.907]	0.533 [0.343 ; 0.717]	2.07	0.47	0.356	0.678 [0.56 ; 0.796]

Lecture simple

Ce qu'on cherche. Pour U2b, la question est de savoir s'il offre un meilleur équilibre entre capacité à détecter les NCB et capacité à éviter des faux positifs.

Comment lire ce résultat. Un test plus équilibré a une sensibilité et une spécificité moins déséquilibrées, mais cela ne suffit pas : il faut aussi regarder ce que devient la probabilité de NCB après un positif (LR+) et après un négatif (LR-).

Ce que montrent les données ici. U2b a Se 0.682, Sp 0.64, VPP 0.769, VPN 0.533, LR+ 1.89, LR- 0.50, Youden 0.322 et AUC 0.661. Son profil est un peu plus équilibré entre sensibilité et spécificité que celui de U2a, mais il reste moins bon que U1 pour ne pas manquer les cas. Un résultat positif est un peu plus crédible qu'avec U2a, mais le gain reste modeste. À l'inverse, un résultat négatif aide moins à faire baisser la probabilité de NCB que pour U1.

Application pratique. U2b a un intérêt comme test de complément, surtout si l'on cherche un profil un peu moins centré sur la sensibilité pure. En revanche, il n'apparaît pas ici comme le meilleur compromis global de la cohorte.

6.B.4 ULNT3

6.B.4.1 Tableau descriptif des résultats des tests

TABLE 19 – Tableau descriptif des résultats de U3 (évaluateur 1)

Test	Positifs n	Positifs %	Négatifs n	Négatifs %
U3	25	36.2	44	63.8

6.B.4.2 Tableau de contingence avec le gold standard

TABLE 20 – Tableau de contingence de U3 par rapport au gold standard, avec effectifs et pourcentages sur l'ensemble des patients analysés

U3	G+	G-	Total
T+	18 (26.1%)	7 (10.1%)	25 (36.2%)
T-	27 (39.1%)	17 (24.6%)	44 (63.8%)
Total	45 (65.2%)	24 (34.8%)	69 (100%)

— T+/T- correspond à Test positif ou négatif, G+/G- correspond à Gold standard positif ou négatif.

6.B.4.3 Tableau des effectifs diagnostiques

TABLE 21 – Effectifs diagnostiques de U3 par rapport au gold standard

Test	N	VP	FN	FP	VN
U3	69	18	27	7	17

6.B.4.4 Tableau des performances diagnostiques

TABLE 22 – Performances diagnostiques de U3 par rapport au gold standard

Test	Se [IC95]	Sp [IC95]	VPP [IC95]	VPN [IC95]	LR+	LR-	Youden	AUC [IC95]
U3	0.4 [0.257 ; 0.557]	0.708 [0.489 ; 0.874]	0.72 [0.506 ; 0.879]	0.386 [0.244 ; 0.545]	1.37	0.85	0.108	0.554 [0.436 ; 0.672]

Lecture simple

Ce qu'on cherche. Ici, on regarde si U3 apporte une information diagnostique utile, soit pour repérer les NCB, soit pour rassurer quand il est négatif.

Comment lire ce résultat. Un test utile doit idéalement garder une bonne sensibilité, une spécificité correcte, et surtout des rapports de vraisemblance qui modifient réellement la probabilité clinique de NCB.

Ce que montrent les données ici. U3 a Se 0.386, Sp 0.68, VPP 0.68, VPN 0.386, LR+ 1.21, LR- 0.90, Youden 0.066 et AUC 0.533. Cela veut dire qu'il manque beaucoup de patients réellement atteints et qu'un résultat négatif aide très peu à écarter la NCB. Son résultat positif renforce aussi faiblement l'hypothèse diagnostique. Sur le plan statistique, l'association avec le gold standard est ici faible, contrairement à U1, U2a et U2b.

Application pratique. Dans cette cohorte, U3 a un faible intérêt isolé. Il paraît nettement moins utile que U1, U2a ou U2b si l'objectif est d'orienter concrètement la décision clinique.

6.C Synthèse globale des tests

6.C.1 Tableau de contingence global

TABLE 23 – Tableau global de contingence des ULNT par rapport au gold standard

Test	VP	FN	FP	VN	N
U1	39	6	9	15	69
U2a	36	9	10	14	69
U2b	31	14	8	16	69
U3	18	27	7	17	69

6.C.2 Tableau global des performances diagnostiques

TABLE 24 – Tableau global des performances diagnostiques des ULNT

Test	Se [IC95]	Sp [IC95]	VPP [IC95]	VPN [IC95]	LR+	LR-	Youden	AUC [IC95]
------	-----------	-----------	------------	------------	-----	-----	--------	------------

U1	0.867 [0.732 ; 0.949]	0.625 [0.406 ; 0.812]	0.812 [0.674 ; 0.911]	0.714 [0.478 ; 0.887]	2.31	0.21	0.492	0.746 [0.635 ; 0.857]
U2a	0.8 [0.654 ; 0.904]	0.583 [0.366 ; 0.779]	0.783 [0.636 ; 0.891]	0.609 [0.385 ; 0.803]	1.92	0.34	0.383	0.692 [0.575 ; 0.808]
U2b	0.689 [0.534 ; 0.818]	0.667 [0.447 ; 0.844]	0.795 [0.635 ; 0.907]	0.533 [0.343 ; 0.717]	2.07	0.47	0.356	0.678 [0.56 ; 0.796]
U3	0.4 [0.257 ; 0.557]	0.708 [0.489 ; 0.874]	0.72 [0.506 ; 0.879]	0.386 [0.244 ; 0.545]	1.37	0.85	0.108	0.554 [0.436 ; 0.672]




FIGURE 9 – Composition des tableaux de contingence 2x2 par test




FIGURE 10 – Comparaison synthétique de la sensibilité et de la spécificité des ULNT

Lecture simple

Ce qu'on cherche. Cette synthèse sert à comparer directement les quatre ULNT pour voir lequel paraît le plus utile dans la cohorte, et surtout pour comprendre **où** chaque test se trompe.

Comment lire ce résultat. La figure sensibilité/spécificité compare la capacité à ne pas manquer les cas d'un côté, et à éviter les faux positifs de l'autre. Le graphique des tableaux 2x2 montre d'où viennent concrètement les erreurs : faux négatifs ou faux positifs.

Ce que montrent les données ici. U1 est le meilleur test isolé de la cohorte avec Se 0.864, Sp 0.60, LR+ 2.16, LR- 0.23, Youden 0.464 et AUC 0.732. U2a et U2b restent utiles, mais un peu moins convaincants. U3 est nettement moins performant, avec Se 0.386, Sp 0.68, LR+ 1.21 et LR- 0.90. En pratique, U1, U2a et U2b repèrent plutôt bien les NCB, mais leur spécificité reste seulement faible à modérée. Aucun des quatre tests n'est à la fois très sensible et très spécifique.

Application pratique. Les ULNT semblent surtout utiles comme **outils d'orientation**, pas comme tests définitifs. U1 est le meilleur point d'entrée, surtout parce qu'un résultat négatif réduit utilement la probabilité de NCB. En revanche, aucun ULNT ne suffit seul pour confirmer ou exclure formellement le diagnostic sans le reste de l'examen clinique et de l'imagerie.

6.D Comparaisons directes entre tests

Le protocole demandait une comparaison des performances diagnostiques entre tests. Comme les **memes patients** passent les différents ULNT, une comparaison appariée de type **McNemar** est plus adaptée qu'un simple khi2 indépendant :

- chez les G+, elle compare les **sensibilités** ;
- chez les G-, elle compare les **spécificités**.

TABLE 25 – Comparaisons appariées entre ULNT pour la sensibilité (chez les G+) (chez les G-)

Comparaison	N G+	Se test 1	Se test 2	Diff Se	Discordance G+ (test1 seul / test2 seul)	p McNemar Se	N G-	Sp test 1	Sp test 2
U1 vs U2a	45	0.867	0.800	0.067	7 / 4	0.546	24	0.625	0.583
U1 vs U2b	45	0.867	0.689	0.178	12 / 4	0.0801	24	0.625	0.667
U1 vs U3	45	0.867	0.400	0.467	22 / 1	<0.001	24	0.625	0.708
U2a vs U2b	45	0.800	0.689	0.111	8 / 3	0.228	24	0.583	0.667
U2a vs U3	45	0.800	0.400	0.400	18 / 0	<0.001	24	0.583	0.708
U2b vs U3	45	0.689	0.400	0.289	18 / 5	0.0123	24	0.667	0.708

Lecture simple

Ce qu'on cherche. Ici, on ne compare pas les tests séparément, mais **les uns contre les autres sur les mêmes patients**. Cela permet de voir si un test manque significativement plus de cas qu'un autre, ou au contraire s'il génère significativement plus de faux positifs.

Comment lire ce résultat. Chez les G+, le tableau compare les **sensibilités**. Chez les G-, il compare les **spécificités**. Une p-value basse signifie qu'un des deux tests se comporte différemment de l'autre sur les mêmes patients.

Ce que montrent les données ici. Les différences nettes portent surtout sur la **sensibilité**. U3 est significativement moins sensible que U1, U2a et U2b, ce qui veut dire qu'il manque plus souvent les patients réellement atteints. En revanche, il n'y a pas de différence claire de spécificité entre les tests dans cette cohorte.

Application pratique. Si la priorité est de limiter les faux négatifs, U3 paraît moins intéressant. Le choix entre U1, U2a et U2b se joue davantage sur leur utilité globale que sur une vraie différence démontrée de spécificité.

6.E Reproductibilité inter-évaluateurs

TABLE 26 – Inter-observer agreement for each ultrasound test

Test	N	Accord	Kappa	IC95% bas	IC95% haut	Interpretation
U1	60	0.883	0.683	0.467	0.899	substantielle
U2a	60	0.833	0.604	0.383	0.824	substantielle
U2b	60	0.817	0.593	0.377	0.808	modérée
U3	60	0.817	0.625	0.425	0.825	substantielle




FIGURE 11 – Kappa inter-observer agreement for each ultrasound test.

Le Kappa de Cohen correspond à la concordance corrigée, c'est à dire le pourcentage d'accord entre les évaluateurs corrigé par le taux d'accord attendu par hasard.

Interprétation selon tableau de Landis & Koch (1977) : - < 0 : pas d'accord - 0.00–0.20 : accord faible - 0.21–0.40 : accord passable - 0.41–0.60 : accord modéré - 0.61–0.80 : accord substantiel - 0.81–1.00 : accord presque parfait

Lecture simple

Ce qu'on cherche. Ici, on veut savoir si deux évaluateurs obtiennent globalement le même résultat lorsqu'ils réalisent les ULNT. Un test peu reproductible est difficile à utiliser en pratique, même s'il semble performant.

Comment lire ce résultat. Le Kappa mesure l'accord entre évaluateurs au-delà de ce qu'on attendrait simplement par hasard. Plus il est proche de 1, plus le test est reproductible. Un accord brut élevé ne suffit pas toujours ; le Kappa est plus informatif.

Ce que montrent les données ici. L'accord est globalement bon à substantiel, avec U1 kappa 0.683, U2a 0.604, U2b 0.593 et U3 0.625. U2b est le moins reproductible du groupe, mais reste à un niveau acceptable. U1 combine ici la meilleure utilité diagnostique et une reproductibilité solide.

Application pratique. Les ULNT semblent globalement transposables entre examinateurs formés. Cela renforce surtout l'intérêt clinique de U1, qui paraît à la fois utile et relativement stable d'un observateur à l'autre.

6.F Combinaisons et score de positivité ULNT

Le protocole prévoyait une exploration des associations entre tests, mais deux objets statistiques différents doivent être distingués ici :

- les **combinaisons conjonctives prédéfinies**, pour lesquelles le résultat est positif seulement si **tous** les tests de la combinaison sont positifs ;
- le **score de positivité ULNT**, qui correspond simplement au **nombre total** de tests positifs, puis à des seuils du type ≥ 1 , ≥ 2 , ≥ 3 ou ≥ 4 .

Un seuil ≥ 3 positifs ne correspond donc **pas** à une combinaison fixe de trois tests : plusieurs profils différents peuvent aboutir à ce score. À l'inverse, une combinaison comme **U2b + U3** impose précisément quels tests doivent être positifs. Enfin, le seuil ≥ 4 positifs correspond à la règle la plus stricte du score, c'est-à-dire **4 tests positifs sur 4**.

6.F.1 Combinaisons conjonctives prédéfinies

TABLE 27 – Résumé des combinaisons les plus sensibles et les plus spécifiques

Profil	Combinaison	Nombre de tests	Se [IC95%]	Sp [IC95%]	LR+	LR-
Combinaison la plus sensible	U1	1	0.867 [0.732 ; 0.949]	0.625 [0.406 ; 0.812]	2.31	0.21
Combinaison la plus spécifique	U2b + U3	2	0.289 [0.164 ; 0.443]	0.792 [0.578 ; 0.929]	1.39	0.90

- Pour résumer les extrêmes, la **combinaison la plus sensible** est U1 seul (Se **0.864**, Sp **0.60**). En cas d'égalité de sensibilité, la combinaison retenue ici est la plus performante en spécificité, puis la plus **parcimonieuse** si besoin.
- La **combinaison la plus spécifique** est U2b + U3 (Sp **0.76**, Se **0.273**). En cas d'égalité de spécificité, la combinaison retenue ici est la plus performante en sensibilité, puis la plus **parcimonieuse** si besoin.
- La spécificité maximale observée pour les combinaisons conjonctives est en réalité partagée par **quatre** combinaisons : U2b + U3, U2a + U2b + U3, U1 + U2b + U3 et les **4 tests**. U2b + U3 est retenue ici parce qu'elle garde la meilleure sensibilité parmi ces ex aequo, puis la meilleure parcimonie.

Lecture simple

Ce qu'on cherche. Ici, on se demande si le fait d'exiger plusieurs tests positifs en même temps permet d'obtenir un résultat plus utile qu'un test isolé.

Comment lire ce résultat. Une combinaison est dite positive seulement si **tous** les tests qui la composent sont positifs. En général, cela augmente la spécificité, mais au prix d'une baisse de sensibilité.

Ce que montrent les données ici. La combinaison la plus sensible est en fait U1 seul (Se **0.864**, Sp **0.60**) ; en cas d'égalité de sensibilité, le départage se fait sur la spécificité puis sur la parcimonie. La spécificité maximale des combinaisons conjonctives est **0.76**, partagée par U2b + U3, U2a + U2b + U3, U1 + U2b + U3 et les **4 tests**. La combinaison retenue comme la plus spécifique est U2b + U3, car elle garde la meilleure sensibilité parmi ces ex aequo (Se **0.273**) puis

TABLE 28 – Combinaisons exhaustives des ULNT avec definition positive conjonctive (tous les tests de la combinaison positifs)

Combinaison	Nombre de tests	N analyse	Se [IC95%]	Sp [IC95%]	VPP [IC95%]	VPN [IC95%]	LR+	LR-	Youden
U1	1	69	0.867 [0.732 ; 0.949]	0.625 [0.406 ; 0.812]	0.812 [0.674 ; 0.911]	0.714 [0.478 ; 0.887]	2.31	0.21	0.492
U2a	1	69	0.8 [0.654 ; 0.904]	0.583 [0.366 ; 0.779]	0.783 [0.636 ; 0.891]	0.609 [0.385 ; 0.803]	1.92	0.34	0.383
U2a + U2b	2	69	0.622 [0.465 ; 0.762]	0.75 [0.533 ; 0.902]	0.824 [0.655 ; 0.932]	0.514 [0.34 ; 0.686]	2.49	0.50	0.372
U2b	1	69	0.689 [0.534 ; 0.818]	0.667 [0.447 ; 0.844]	0.795 [0.635 ; 0.907]	0.533 [0.343 ; 0.717]	2.07	0.47	0.356
U1 + U2b	2	69	0.6 [0.443 ; 0.743]	0.75 [0.533 ; 0.902]	0.818 [0.645 ; 0.93]	0.5 [0.329 ; 0.671]	2.40	0.53	0.350
U1 + U2a	2	69	0.711 [0.557 ; 0.836]	0.625 [0.406 ; 0.812]	0.78 [0.624 ; 0.894]	0.536 [0.339 ; 0.725]	1.90	0.46	0.336
U1 + U2a + U2b	3	69	0.533 [0.379 ; 0.683]	0.75 [0.533 ; 0.902]	0.8 [0.614 ; 0.923]	0.462 [0.301 ; 0.628]	2.13	0.62	0.283
U3	1	69	0.4 [0.257 ; 0.557]	0.708 [0.489 ; 0.874]	0.72 [0.506 ; 0.879]	0.386 [0.244 ; 0.545]	1.37	0.85	0.108
U2a + U3	2	69	0.4 [0.257 ; 0.557]	0.708 [0.489 ; 0.874]	0.72 [0.506 ; 0.879]	0.386 [0.244 ; 0.545]	1.37	0.85	0.108
U1 + U3	2	69	0.378 [0.238 ; 0.535]	0.708 [0.489 ; 0.874]	0.708 [0.489 ; 0.874]	0.378 [0.238 ; 0.535]	1.30	0.88	0.086
U1 + U2a + U3	3	69	0.378 [0.238 ; 0.535]	0.708 [0.489 ; 0.874]	0.708 [0.489 ; 0.874]	0.378 [0.238 ; 0.535]	1.30	0.88	0.086
U2b + U3	2	69	0.289 [0.164 ; 0.443]	0.792 [0.578 ; 0.929]	0.722 [0.465 ; 0.903]	0.373 [0.241 ; 0.519]	1.39	0.90	0.081
U2a + U2b + U3	3	69	0.289 [0.164 ; 0.443]	0.792 [0.578 ; 0.929]	0.722 [0.465 ; 0.903]	0.373 [0.241 ; 0.519]	1.39	0.90	0.081
U1 + U2b + U3	3	69	0.267 [0.146 ; 0.419]	0.792 [0.578 ; 0.929]	0.706 [0.44 ; 0.897]	0.365 [0.236 ; 0.51]	1.28	0.93	0.058
U1 + U2a + U2b + U3	4	69	0.267 [0.146 ; 0.419]	0.792 [0.578 ; 0.929]	0.706 [0.44 ; 0.897]	0.365 [0.236 ; 0.51]	1.28	0.93	0.058

la meilleure parcimonie. Cela illustre bien le compromis attendu : quand on cherche surtout la spécificité, on perd beaucoup en sensibilité. Par exemple, U2a + U2b améliore un peu la spécificité (0.72) mais perd en sensibilité (0.614). Plus les combinaisons deviennent strictes, plus elles ratent de patients réellement atteints. Dans cette lecture conjonctive, la meilleure combinaison exploratoire selon Youden reste finalement U1 seul (Youden = 0.464).

Application pratique. Demander plusieurs tests positifs peut rendre le résultat plus “convaincant”, mais fait rater davantage de NCB. Sur ces données, cela ne justifie pas de remplacer U1 par une règle conjonctive.

6.F.2 Score ULNT : probabilité selon le nombre exact de tests positifs

TABLE 29

TABLE 30 – Probabilité observée de NCB selon le nombre exact de tests positifs

Nombre de tests positifs	Effectif (N)	Nombre de NCB	Probabilité de NCB [IC95%]
0	14	2	0.143 [0.018 ; 0.428]
1	7	4	0.571 [0.184 ; 0.901]
2	10	9	0.9 [0.555 ; 0.997]
3	21	18	0.857 [0.637 ; 0.97]
4	17	12	0.706 [0.44 ; 0.897]




FIGURE 12 – Probabilité observée de NCB selon le nombre de tests positifs.

Lecture simple

Ce qu'on cherche. Cette section répond à une question très intuitive : plus il y a de tests ULNT positifs, plus la probabilité de NCB augmente-t-elle ?

Comment lire ce résultat. Le tableau donne la probabilité de NCB observée pour 0, 1, 2, 3 ou 4 tests positifs, quel que soit le détail exact des tests positifs. Le modèle logistique résume ensuite la tendance globale, et l'AUC dit si ce score sépare correctement, ou non, les patients positifs et négatifs.

Ce que montrent les données ici. La probabilité observée de NCB passe de 14 % avec 0 test positif à 57 % avec 1, puis 90 % avec 2, 86 % avec 3, et 65 % avec 4 tests positifs. Les irrégularités aux scores élevés viennent des petits effectifs dans chaque case. Le modèle retrouve bien une tendance globale croissante : chaque test positif supplémentaire est associé à un OR 1.833 de NCB (IC95 [1.256 ; 2.674], $p = 0.0017$). L'AUC du score est 0.693, ce qui reste modeste et ne surpasse pas clairement U1 seul.

Application pratique. Le cumul de positivité renforce la suspicion de NCB et peut aider à structurer le raisonnement. En revanche, ce score reste un outil d'orientation : il ne remplace ni le meilleur test isolé, ni le contexte clinique global.

6.F.3 Score ULNT : performances selon les seuils

L'objectif ici est de calculer les performances diagnostiques (sensibilité, spécificité, LR+, LR-, Youden, DOR) pour différents seuils de score (≥ 1 , ≥ 2 , ≥ 3 , ≥ 4 tests positifs). Cela permet d'évaluer comment la performance diagnostique évolue en fonction du nombre de tests positifs.

En pratique, cela revient à demander si un seuil du type “au moins 2 tests positifs” est plus utile qu'un test isolé. Cette logique reste différente de celle des combinaisons conjonctives : ≥ 3 positifs ne précise pas quels tests sont positifs, alors que U2b + U3 impose une paire fixe de tests positifs.

Le **DOR** (diagnostic odds ratio) correspond au ratio $(VP \cdot VN) / (FP \cdot FN)$. Plus il est élevé, meilleure est la séparation globale entre patients positifs et négatifs, mais cette métrique doit rester secondaire ici faute d'intervalle de confiance.

TABLE 31 – Performances diagnostiques selon le seuil du score

Seuil	Se [IC95%]	Sp [IC95%]	LR+	LR-	Youden	DOR
≥ 1 positif	0.956 [0.849 ; 0.995]	0.5 [0.291 ; 0.709]	1.911	0.089	0.456	21.500
≥ 2 positifs	0.867 [0.732 ; 0.949]	0.625 [0.406 ; 0.812]	2.311	0.213	0.492	10.833
≥ 3 positifs	0.667 [0.51 ; 0.8]	0.667 [0.447 ; 0.844]	2.000	0.500	0.333	4.000
≥ 4 positifs	0.267 [0.146 ; 0.419]	0.792 [0.578 ; 0.929]	1.280	0.926	0.058	1.382

Lecture simple

Ce qu'on cherche. Ici, on ne regarde plus le nombre exact de tests positifs, mais des règles simples du type “au moins 1”, “au moins 2”, “au moins 3” ou “au moins 4” tests positifs.

Comment lire ce résultat. Un seuil bas est souvent très sensible mais peu spécifique. Un seuil élevé devient plus spécifique mais risque de manquer beaucoup de cas. Le meilleur seuil est celui qui offre le compromis le plus acceptable pour l'usage clinique visé.

Ce que montrent les données ici. ≥ 1 positif est très sensible (Se 0.955) mais peu spécifique (Sp 0.48). Parmi les seuils du score, la spécificité la plus élevée est obtenue pour ≥ 4 positifs avec Sp 0.76 et Se 0.250, ce qui correspond en pratique à exiger 4 tests positifs sur 4. Le meilleur compromis exploratoire reste ≥ 2 positifs, avec Se 0.864, Sp 0.60 et Youden 0.464. Cela correspond en pratique au même niveau de compromis que U1 seul, sans supériorité nette.

Application pratique. Si un score doit être utilisé, le seuil ≥ 2 paraît le plus raisonnable dans cette cohorte. En revanche, il n'apporte pas de bénéfice clair par rapport à U1 seul, qui reste plus simple à utiliser et au moins aussi informatif.

6.G Analyses exploratoires par niveau métamérique

Cette section est volontairement présentée **après** les analyses principales, car son objectif est exploratoire. Elle réintroduit le détail par niveau métamérique dans un cadre explicitement prudent :

- les effectifs restent modestes (1 à 27 dossiers analysés selon le niveau) ;
- C4 est conservé comme catégorie distincte malgré un seul dossier ;
- aucune interprétation robuste ne doit reposer sur une seule cellule isolée.


6.G.1 Résumé descriptif par niveau métamérique

TABLE 32 – Résumé descriptif par niveau métamérique

Niveau	N analyse	NCB positif	NCB négatif	Effectif total du niveau	Mediane score ULNT [Q1 ; Q3]
C4	1	1	0	1	0 [0 ; 0]
C5	10	5	5	10	1 [0 ; 3.75]
C6	27	19	8	27	3 [2 ; 3]
C7	21	13	8	21	3 [1 ; 4]
C8	10	7	3	10	1.5 [0.25 ; 3]


- Le tableau distingue ici l'**effectif total du niveau** et l'**effectif analysé** après exclusion des statuts non interprétables du gold standard.

Effectifs de NCB selon le niveau metamerique



- Ce premier graphique montre les **effectifs** de NCB positif et NCB négatif par niveau. C4 y apparaît bien avec **1 dossier positif** et **0 négatif**.

Distribution du score ULNT selon le niveau metamerique



— Ce second graphique montre la **distribution du score ULNT de 0 a 4**. C4 y apparait avec un unique patient de **score 0**, ce qui explique le 0 vu auparavant sur le graphique de moyenne.

Lecture simple

Ce qu'on cherche. Ici, on cherche à savoir si certains niveaux métamériques semblent associés à une fréquence différente de NCB ou à un profil différent de positivité des ULNT.

Comment lire ce résultat. Avant même de regarder les performances diagnostiques, il faut regarder **combien** de patients sont présents à chaque niveau. Sans effectif suffisant, un résultat très bon ou très mauvais peut être dû au hasard.

Ce que montrent les données ici. Les niveaux C6 et C7 concentrent le plus d'observations (27 et 21 dossiers analysés), alors que C4 ne comporte qu'un seul patient et C5 10. Le score ULNT paraît plus élevé surtout en C6 et C7, mais cela reste une lecture descriptive. À ce stade, on peut dire qu'il existe des différences apparentes entre niveaux, sans pouvoir encore conclure qu'elles sont robustes.

Application pratique. Cette partie doit surtout servir à formuler des hypothèses. Il ne faut pas modifier sa pratique sur la seule base de C4 ou de C5, où les effectifs sont trop faibles.

6.G.2 Détail exploratoire test par test et niveau par niveau

TABLE 33 – Performances diagnostiques exploratoires des ULNT selon le niveau métamérique

Niveau	Test	N analyse	TP	FP	TN	FN	Se [IC95% exact]	Sp [IC95% exact]	p Fisher
C4	U1	1	0	0	0	1	0 [0 ; 0.975]	NA	NA
C4	U2a	1	0	0	0	1	0 [0 ; 0.975]	NA	NA
C4	U2b	1	0	0	0	1	0 [0 ; 0.975]	NA	NA
C4	U3	1	0	0	0	1	0 [0 ; 0.975]	NA	NA
C5	U1	10	5	0	5	0	1 [0.478 ; 1]	1 [0.478 ; 1]	0.00794
C5	U2a	10	5	0	5	0	1 [0.478 ; 1]	1 [0.478 ; 1]	0.00794
C5	U2b	10	4	0	5	1	0.8 [0.284 ; 0.995]	1 [0.478 ; 1]	0.0476

TABLE 33 – Performances diagnostiques exploratoires des ULNT selon le niveau métamérique
(continued)

Niveau	Test	N analyse	TP	FP	TN	FN	Se [IC95% exact]	Sp [IC95% exact]	p Fisher
C5	U3	10	3	0	5	2	0.6 [0.147 ; 0.947]	1 [0.478 ; 1]	0.167
C6	U1	27	17	6	2	2	0.895 [0.669 ; 0.987]	0.25 [0.032 ; 0.651]	0.558
C6	U2a	27	16	6	2	3	0.842 [0.604 ; 0.966]	0.25 [0.032 ; 0.651]	0.616
C6	U2b	27	10	5	3	9	0.526 [0.289 ; 0.756]	0.375 [0.085 ; 0.755]	0.696
C6	U3	27	9	5	3	10	0.474 [0.244 ; 0.711]	0.375 [0.085 ; 0.755]	0.678
C7	U1	21	11	3	5	2	0.846 [0.546 ; 0.981]	0.625 [0.245 ; 0.915]	0.0555
C7	U2a	21	11	3	5	2	0.846 [0.546 ; 0.981]	0.625 [0.245 ; 0.915]	0.0555
C7	U2b	21	12	3	5	1	0.923 [0.64 ; 0.998]	0.625 [0.245 ; 0.915]	0.0139
C7	U3	21	4	2	6	9	0.308 [0.091 ; 0.614]	0.75 [0.349 ; 0.968]	1
C8	U1	10	6	0	3	1	0.857 [0.421 ; 0.996]	1 [0.292 ; 1]	0.0333
C8	U2a	10	4	1	2	3	0.571 [0.184 ; 0.901]	0.667 [0.094 ; 0.992]	1
C8	U2b	10	5	0	3	2	0.714 [0.29 ; 0.963]	1 [0.292 ; 1]	0.167
C8	U3	10	2	0	3	5	0.286 [0.037 ; 0.71]	1 [0.292 ; 1]	1

Lecture simple

Ce qu'on cherche. Ce tableau détaille, pour chaque test et chaque niveau, combien de patients sont correctement ou incorrectement classés. L'objectif est de voir si un ULNT semble mieux fonctionner à certains niveaux qu'à d'autres.


Comment lire ce résultat. TP, FP, TN et FN décrivent concrètement les bonnes et mauvaises classifications. Les IC95% montrent l'incertitude autour de la sensibilité et de la spécificité. Quand ils sont très larges, cela veut dire qu'on sait peu de choses malgré une valeur parfois spectaculaire.

Ce que montrent les données ici. Les résultats extrêmes dans les petits niveaux ne doivent pas être surinterprétés. C5 paraît très favorable pour plusieurs tests, mais sur un effectif très petit. C6 est plus informatif, car plus peuplé, mais les performances y restent variables selon le test. C7 montre des sensibilités élevées pour U1, U2a et surtout U2b, avec une spécificité seulement moyenne. U3 reste globalement le test le plus faible selon les niveaux.

Application pratique. Ce tableau peut aider à repérer des tendances, mais il ne justifie pas à lui seul de choisir un ULNT différent selon le niveau métamérique. Les petits effectifs imposent de rester prudent.

6.G.3 Lecture test par test selon le niveau métamérique

Sensibilité et spécificité selon le niveau métamérique pour chaque



— Ce graphique remet la lecture **test par test** : chaque facette correspond à un ULNT, avec la sensibilité et la spécificité estimées selon le niveau métamérique.

6.G.3.1 U1 selon le niveau métamérique

TABLE 34 – U1 selon le niveau métamérique

Niveau	N analyse	TP	FP	TN	FN	Se [IC95% exact]	Sp [IC95% exact]	p Fisher
C4	1	0	0	0	1	0 [0 ; 0.975]	NA	NA
C5	10	5	0	5	0	1 [0.478 ; 1]	1 [0.478 ; 1]	0.00794
C6	27	17	6	2	2	0.895 [0.669 ; 0.987]	0.25 [0.032 ; 0.651]	0.558
C7	21	11	3	5	2	0.846 [0.546 ; 0.981]	0.625 [0.245 ; 0.915]	0.0555
C8	10	6	0	3	1	0.857 [0.421 ; 0.996]	1 [0.292 ; 1]	0.0333

6.G.3.2 U2a selon le niveau métamérique

TABLE 35 – U2a selon le niveau métamérique

Niveau	N analyse	TP	FP	TN	FN	Se [IC95% exact]	Sp [IC95% exact]	p Fisher
C4	1	0	0	0	1	0 [0 ; 0.975]	NA	NA
C5	10	5	0	5	0	1 [0.478 ; 1]	1 [0.478 ; 1]	0.00794
C6	27	16	6	2	3	0.842 [0.604 ; 0.966]	0.25 [0.032 ; 0.651]	0.616
C7	21	11	3	5	2	0.846 [0.546 ; 0.981]	0.625 [0.245 ; 0.915]	0.0555

Niveau	N analyse	TP	FP	TN	FN	Se [IC95% exact]	Sp [IC95% exact]	p Fisher
C8	10	4	1	2	3	0.571 [0.184 ; 0.901]	0.667 [0.094 ; 0.992]	1

6.G.3.3 U2b selon le niveau métamérique

TABLE 36 – U2b selon le niveau métamérique

Niveau	N analyse	TP	FP	TN	FN	Se [IC95% exact]	Sp [IC95% exact]	p Fisher
C4	1	0	0	0	1	0 [0 ; 0.975]	NA	NA
C5	10	4	0	5	1	0.8 [0.284 ; 0.995]	1 [0.478 ; 1]	0.0476
C6	27	10	5	3	9	0.526 [0.289 ; 0.756]	0.375 [0.085 ; 0.755]	0.696
C7	21	12	3	5	1	0.923 [0.64 ; 0.998]	0.625 [0.245 ; 0.915]	0.0139
C8	10	5	0	3	2	0.714 [0.29 ; 0.963]	1 [0.292 ; 1]	0.167

6.G.3.4 U3 selon le niveau métamérique

TABLE 37 – U3 selon le niveau métamérique

Niveau	N analyse	TP	FP	TN	FN	Se [IC95% exact]	Sp [IC95% exact]	p Fisher
C4	1	0	0	0	1	0 [0 ; 0.975]	NA	NA
C5	10	3	0	5	2	0.6 [0.147 ; 0.947]	1 [0.478 ; 1]	0.167
C6	27	9	5	3	10	0.474 [0.244 ; 0.711]	0.375 [0.085 ; 0.755]	0.678
C7	21	4	2	6	9	0.308 [0.091 ; 0.614]	0.75 [0.349 ; 0.968]	1
C8	10	2	0	3	5	0.286 [0.037 ; 0.71]	1 [0.292 ; 1]	1

Lecture simple

Ce qu'on cherche. Ces quatre tableaux permettent de regarder chaque ULNT séparément pour voir si son profil change beaucoup selon le niveau métamérique.

Comment lire ce résultat. Il faut surtout chercher une **cohérence globale** d'un niveau à l'autre, plutôt qu'une valeur spectaculaire isolée. Une performance très élevée sur très petit effectif ne suffit pas à faire conclure à un "meilleur niveau".

Ce que montrent les données ici. U1 paraît plutôt fort en C6–C8, avec des résultats particulièrement bons en C5, mais ce dernier niveau est trop petit pour conclure. U2a est proche de U1 en C5–C7, avec un profil plus irrégulier en C8. U2b semble particulièrement sensible en C7, sans preuve robuste d'un niveau vraiment idéal. U3 est plus variable et souvent moins sensible que les autres tests.

Application pratique. Il ne paraît pas pertinent de choisir principalement le test en fonction du niveau métamérique. Le message pratique reste surtout que U1, U2a et U2b gardent plus d'intérêt global que U3.

6.G.4 Modélisation globale du niveau métamérique

TABLE 38 – Effet global du niveau métamérique et du score ULNT sur la probabilité de NCB

Analyse	OR	IC95	p
Niveau seul (OR par palier métamérique)	1.079337	[0.642 ; 1.815]	0.773000
Score ULNT (OR par test positif supplémentaire)	1.976006	[1.334 ; 2.927]	0.000678
Niveau ajusté sur le score ULNT (OR par palier)	1.070474	[0.604 ; 1.896]	0.815000

Lecture simple

Ce qu'on cherche. Ce modèle sert à répondre à une question plus globale : le niveau métamérique apporte-t-il une information propre sur la probabilité de NCB, indépendamment du nombre de tests ULNT positifs ?

Comment lire ce résultat. Un OR proche de 1 signifie qu'il n'y a pas de relation claire. Si l'intervalle de confiance contient largement 1 et que la p-value est élevée, on ne peut pas conclure à un effet robuste.

Ce que montrent les données ici. Le niveau seul a un OR 0.967 [0.578 ; 1.617], $p = 0.897$, ce qui ne suggère aucun signal utile. Après ajustement sur le score ULNT, le niveau reste sans effet clair avec OR 0.943 [0.542 ; 1.639], $p = 0.834$. En revanche, le score ULNT garde un signal net : OR 1.833 [1.256 ; 2.674], $p = 0.0017$. Autrement dit, c'est surtout l'accumulation de tests positifs qui augmente la probabilité de NCB.

Application pratique. Sur ces données, il vaut mieux raisonner d'abord sur le **profil global des ULNT** que sur le niveau métamérique pris isolément. Le niveau ne semble pas apporter d'information indépendante suffisamment robuste pour guider seul la décision.

Références